

Renato Valladares Panaro

**Modelagem e Previsão da Inflação Anual
Efetiva medida pelo IPCA**

Niterói - RJ, Brasil

12 de janeiro de 2017

Renato Valladares Panaro

Modelagem e Previsão da Inflação Anual Efetiva medida pelo IPCA

Trabalho de Conclusão de Curso

Monografia apresentada para obtenção do grau de Bacharel em Estatística pela Universidade Federal Fluminense.

Orientadores: Prof. Ana Beatriz Monteiro Fonseca

Prof. Victor Eduardo Leite de Almeida Duca

Niterói - RJ, Brasil

12 de janeiro de 2017

P187 Panaro, Renato Valladares
Modelagem e previsão da inflação anual efetiva medida pelo IPCA
/ Renato Valladares Panaro. – Niterói, RJ: [s.n.], 2017.

62f.

Orientador: Prof.^a Dr.^a Ana Beatriz Monteiro Fonseca
TCC (Graduação de Bacharelado em Estatística) – Universidade
Federal Fluminense, 2017.

1. Inflação. 2. Séries Temporais. 3. Modelagem (matemática) I.
Título

CDD 519.232

Renato Valladares Panaro

**Modelagem e Previsão da Inflação Anual
Efetiva medida pelo IPCA**

Monografia de Projeto Final de Graduação sob o título “ *Modelagem e Previsão da Inflação Anual Efetiva medida pelo IPCA*”, defendida por Renato Valladares Panaro e aprovada em 12 de janeiro de 2017, na cidade de Niterói, no Estado do Rio de Janeiro, pela banca examinadora constituída pelos professores:

Profa. Dra. Ana Beatriz Monteiro Fonseca
Universidade Federal Fluminense

Profa. Dra. Núbia Karla de Oliveira Almeida
Universidade Federal Fluminense

Prof. Me. Victor Eduardo Leite de Almeida Duca
Universidade Federal do Rio de Janeiro

Niterói, 12 de janeiro de 2017

Resumo

A inflação é o aumento do nível dos preços de um determinado produto ao longo do tempo. Hoje, a inflação oficial dos bens e serviços presentes na economia brasileira é medida pelo Índice de Preços ao Consumidor Amplo (IPCA) e essa medida representa o aumento ou a diminuição dos preços em um determinado período. A alta inflação é prejudicial para a economia de um país e, quando fora de controle, pode gerar diversos problemas, tais como, a desvalorização da moeda nacional e aumento dos preços de produtos importados, a diminuição dos investimentos no setor produtivo, aumento da especulação financeira, elevação da taxa de juros e aumento do desemprego, além do clima de instabilidade econômica e insatisfação popular. Para conter a inflação, no Brasil, desde 1999, é adotada a política de metas de inflação que consiste em manter a inflação anual dentro do intervalo de tolerância estipulado para o ano, conforme estabelecido pelo Conselho Monetário Nacional (CMN).

O objetivo desse trabalho consiste em avaliar a série histórica do IPCA, considerando os índices produzidos entre dezembro de 1999 e outubro de 2017 (inclusive) e identificar, estimar e comparar modelos. Para tanto, foram depurados dados mensais do Sistema IBGE de Recuperação Automática (SIDRA) referentes ao IPCA acumulado anual. O foco do estudo é modelar e produzir estimativas para valores futuros do IPCA e, dessa forma, identificar padrões e tendências presentes na economia do Brasil por meio de modelos que serão comparados em termos de parcimônia, ajuste e qualidade das previsões. Serão utilizados métodos para séries temporais do tipo SARIMA e suas derivações.

Dentre os principais resultados, verificou-se que os modelos do tipo SARIMA não demonstram capacidade preditiva a longo prazo. Foram confrontados os modelos de Box-Jenkins de melhor estimação. Escolhidos através do critério AIC, os modelos SARIMA $SARIMA(1, 1, 2)(2, 0, 3)_{12}$; $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ e $SARIMA(1, 1, 3)(2, 0, 2)_{12}$ apresentaram erros de estimação próximos a zero, já as previsões, foram comparadas com os valores do IPCA Efetivo, de junho de 2016 a novembro de 2017 e apresentaram erros de previsão expressivos. Além disso, a apuração dos resultados também permitiu compreender melhor o comportamento da série.

Palavras-chaves: Modelagem, Box-Jenkins, autoregressivo, séries temporais, índice, IPCA, inflação.

Dedicatória

Dedico este trabalho aos meus pais, que nunca mediram esforços para dar suporte à minha formação básica e superior.

“Statistics is the art of never having to say you’re wrong. Variance is what any two statisticians are at.- C.J.Bradfield ”

Agradecimentos

Agradeço a todos aqueles que conviveram comigo na Universidade Federal Fluminense, em meio a todas as descobertas e aventuras, ajudaram a fazer com que a busca pelo conhecimento não perdesse o seu brilho.

A todos os professores do Departamento de Estatística pela transmissão segura e paciente de conhecimento.

Ao meu pai, Eduardo, pelo companheirismo e lealdade. À minha mãe, Magali, por todo o carinho e ao meu irmão, Leonardo, pelo otimismo.

À minha família, especialmente minha madrinha Madalena e meus avós. À eles, o meu sincero agradecimento por toda a alegria e apoio.

Agradeço aos meus orientadores professora Ana Beatriz Fonseca e professor Victor Duca, que prontamente e com grande entusiasmo aceitaram fazer parte desse momento tão importante da minha vida. Extendo esse agradecimento especial à professora Núbia que compôs a banca examinadora.

Agradeço ao professor Gilberto Sassi pelas excelentes aulas de séries temporais.

Agradeço aos meus grandes amigos, Gabriel Agostini, Jorge Rachid e Deyvid Toledo. Finalmente, agradeço Juliana Conhasco, por saber entender e ter paciência nos momentos de minha ausência, para dedicação aos estudos.

Sumário

Lista de Figuras

Lista de Tabelas

1	Introdução	p. 12
1.1	Os Índices de Preços no Brasil	p. 12
1.1.1	O Índice de Preços ao Consumidor	p. 13
1.1.2	O Índice de Preços ao Consumidor Amplo	p. 14
1.2	A Inflação	p. 15
1.3	Métodos para Previsão da Inflação	p. 18
2	Objetivos	p. 21
3	Materiais e Métodos	p. 22
3.1	A Série Histórica	p. 22
3.2	Metodologia	p. 22
3.2.1	Conceitos Básicos	p. 23
3.2.2	Função de Autocovariância	p. 25
3.2.3	Função de Autocorrelação e Função de Autocorrelação Parcial .	p. 26
3.2.4	Modelos Box-Jenkins	p. 28
3.2.4.1	Causalidade e Invertibilidade	p. 28
3.2.4.2	Modelo Autoregressivo e de Médias Móveis Integrado - ARIMA	p. 29
3.2.4.3	Modelo ARIMA Sazonal - SARIMA	p. 30

3.2.5	Busca Iterativa do Melhor Modelo	p. 31
3.2.5.1	Identificação de Modelos	p. 32
3.2.5.2	Estimação (método dos momentos): equações de Yule-Walker	p. 33
3.2.5.3	Análise dos Resíduos	p. 34
3.2.6	Testes para Identificação de Componentes	p. 36
3.2.6.1	Testes de Wald-Wolfowitz para Tendência	p. 36
3.2.6.2	Teste de Correlação de postos de Spearman para Tendência	p. 36
3.2.6.3	Análise de Variância para Sazonalidade	p. 37
3.2.6.4	Coeficiente de Assimetria	p. 37
3.2.7	Critérios de Comparação de Modelos	p. 38
3.2.7.1	Critério de Informação de Akaike	p. 38
3.2.7.2	Critério de Informação Bayesiano	p. 38
3.2.7.3	Erro Absoluto Médio	p. 39
3.2.7.4	Erro Médio Percentual	p. 39
3.2.7.5	Erro Médio Absoluto Percentual	p. 39
3.2.7.6	Raiz do Erro Quadrático Médio	p. 39
3.2.8	Transformação de Box-Cox	p. 40
4	Análise dos Resultados	p. 41
5	Conclusão	p. 59
	Referências	p. 60
	Anexo A – Programação estatística	p. 63
	Anexo B – Tabelas e Outros Resultados	p. 66

Lista de Figuras

1	Processo Estocástico representado como família de variáveis aleatórias.	p. 23
2	Representação do Processo Linear. Fonte: Morettin e Toloi (2006) . . .	p. 28
3	Metodologia Box-Jenkins. Fonte: Martinez (2015)	p. 31
4	Série histórica do IPCA de janeiro de 1994 a novembro de 2017.	p. 41
5	Série histórica do IPCA acumulado por ano, de dezembro de 1999 a maio de 2016.	p. 42
6	Histograma das transformações Box-Cox.	p. 44
7	Transformação Box-Cox com $\lambda = -0,4$	p. 45
8	Transformação Box-Cox ($\lambda = -0.4$) por mês.	p. 46
9	FAC e FACP até a defasagem 60.	p. 47
10	Histograma do IPCA após a primeira diferenciação.	p. 48
11	FAC e FACP da série diferenciada.	p. 48
12	Resíduos do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$	p. 52
13	FAC e FACP dos resíduos do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$	p. 52
14	Previsão usando o modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$	p. 53
15	Resíduos do modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$	p. 54
16	FAC e FACP dos resíduos do modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$	p. 54
17	Previsão usando o modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$	p. 55
18	Resíduos do modelo SARIMA $(1, 1, 3)(2, 0, 2)_{12}$	p. 56
19	FAC e FACP do modelo SARIMA $(1, 1, 3)(2, 0, 2)_{12}$	p. 56
20	Previsão usando o modelo SARIMA $(1, 1, 3)(2, 0, 2)_{12}$	p. 57

21	Previsão, estimação, limites do intervalo de confiança de 95% e IPCA observado.	p. 58
22	Transformação Box-Cox com (d=1)	p. 66

Lista de Tabelas

1	Características dos Principais Índices de Preços ao Consumidor	p. 14
2	Histórico de Metas para a Inflação no Brasil	p. 17
3	Comportamento característico da FAC e FACP (Identificação)	p. 32
4	Comportamento característico da FAC e FACP para ajustes sazonais (Identificação)	p. 33
5	Análise de Variância	p. 37
6	Testes para tendência.	p. 43
7	Teste de shapiro-wilk para o IPCA transformado.	p. 44
8	Modelos ordenados pelo AIC.	p. 49
9	Modelos ordenados pelo BIC.	p. 50
10	Coeficientes dos modelos SARIMA.	p. 50
11	Medidas de qualidade de ajuste.	p. 51
12	Medidas de qualidade de previsão.	p. 57
13	Valores Discrepantes do IPCA	p. 67
14	IPCA Tranformado por mês.	p. 68
15	Previsão, intervalo e erro de previsão para o SARIMA $(1, 1, 2)(2, 0, 3)_{12}$	p. 69
16	Previsão, limite do intervalo de confiança e erro absoluto de previsão para o modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$	p. 69
17	Previsão, intervalo e erro de previsão para o modelo SARIMA $(1, 1, 3)(2, 0, 2)_{12}$	p. 70
18	Modelos segundo os critérios de informação AIC e BIC e RMSE	p. 71

1 Introdução

Um indicador econômico é usado por especialistas para interpretar as possibilidades de investimento atuais e projetar as futuras, assim como, avaliar o estado geral de uma economia. Periodicamente, dados estatísticos são amplamente divulgados por organizações governamentais e, segundo a Organização para a Cooperação e Desenvolvimento Econômico (OCDE, 2006), são utilizados por líderes corporativos e governamentais para antecipar, ou postergar, as tomadas de decisão quanto a transações e especulações na compra e venda de títulos, ações e investimentos.

1.1 Os Índices de Preços no Brasil

Na categoria de indicadores econômicos, enquadram-se os índices de preços, os quais medem a variação média dos preços dos produtos que compõem uma determinada cesta. O cálculo desse tipo de índice envolve uma série de fatores descritos no relatório metodológico Métodos de Cálculo (IBGE, 2006) do Sistema Nacional de Preços ao Consumidor (SNIPC), tais como a definição do seu objetivo; da região e da periodicidade da coleta; dos bens e serviços pesquisados e da metodologia do cálculo que combina em única medida a variação do preço dos bens de consumo e serviços.

Os índices de preços foram produzidos ao longo dos anos, com diferentes finalidades. O IPC-Fipe, por exemplo, foi criado pela Prefeitura de São Paulo, com o objetivo de reajustar os salários dos servidores municipais. O Índice Geral de Preços – Mercado (IGP-M) foi instituído para ser usado no reajuste de operações financeiras e o Índice Geral de Preços – Disponibilidade Interna (IGP-DI) para balizar o comportamento dos preços em geral da economia. O Índice Nacional de Preços ao Consumidor (INPC) é o índice balizador dos reajustes de salário, e o IPCA corrige os balanços e demonstrações financeiras trimestrais e semestrais das companhias, além de ser o medidor oficial da inflação no país.

Em síntese, os índices de preços são números que agregam e representam os preços de determinada cesta de produtos, podendo se referir, por exemplo, a preços ao consumidor, preços ao produtor, custos de produção ou preços de exportação e importação. Os índices mais difundidos são os índices de preços ao consumidor, uma vez que medem a variação do custo de vida de segmentos da população (inflação ou deflação).

1.1.1 O Índice de Preços ao Consumidor

O IPCA compreende famílias residentes nas áreas urbanas, com rendimentos mensais entre um e quarenta salários mínimos de 10 regiões metropolitanas brasileiras, além das cidades de Brasília, Goiânia e Campo Grande. O IPCA-15 difere do IPCA quanto ao período de coleta (do dia 16 do mês anterior ao 15 do mês de referência) e não inclui a região metropolitana de Vitória e o município de Campo Grande. O INPC é calculado de acordo com famílias de rendimentos mensais entre 1 e 5 salários e abrange as mesmas regiões urbanas do IPCA. Já o IPC-Fipe é calculado, somente para o município de São Paulo, na faixa de 1 a 10 salários.

A Tabela 1 apresenta os principais índices de preços ao consumidor empregados no Brasil. Os índices de preços ao consumidor são produzidos pelo Instituto Brasileiro de Geografia e Estatística - IBGE (IPCA e INPC); os índices gerais de preços são produzidos pela Fundação Getúlio Vargas (FGV) e o índice de preços ao consumidor produzido pela Fundação Instituto de Pesquisas Econômicas (Fipe) é o IPC-Fipe. Destaca-se o IPCA que é considerado o mais relevante dos índices utilizados no Brasil.

Tabela 1: Características dos Principais Índices de Preços ao Consumidor

Instituto	Índice	Faixa de renda (em salários mínimos)	Área de abrangência	Desde
IBGE	IPCA-15	1 a 40	Regiões Metropolitanas do Rio de Janeiro, Porto Alegre, Belo Horizonte, Recife, São Paulo, Belém, Fortaleza, Salvador e Curitiba, além do Distrito Federal e do município de Goiânia.	2000
	IPCA	1 a 40	Regiões metropolitanas de Belém, Fortaleza, Recife, Salvador, Belo Horizonte, Vitória, Rio de Janeiro, São Paulo, Curitiba, Porto Alegre, além do Distrito Federal e dos municípios de Goiânia e Campo Grande.	1979
	INPC	1 a 5		1979
Fipe	IPC-Fipe	1 a 10	Município de São Paulo	1939

Fontes: IBGE, FGV e Fipe

1.1.2 O Índice de Preços ao Consumidor Amplo

As estruturas de ponderação utilizadas para o cálculo do IPCA resultam da consolidação dos orçamentos familiares levantados pela Pesquisa de Orçamentos Familiares (POF) realizada de 2008 a 2009, a POF é realizada em estabelecimentos comerciais, prestadores de serviços, domicílios e concessionárias de serviços públicos com abrangência descrita na Tabela 1. A Pesquisa de Locais de Compra (PLC), desde 1988, fornece o cadastro de informantes da pesquisa, cuja manutenção é contínua e a Pesquisa de Especificação de Produtos e Serviços (PEPS) fornece cadastro de produtos e serviços pesquisados, permanentemente atualizado com o objetivo de acompanhar a dinâmica de mercado.

O cálculo do IPCA entre os meses $t - 1$ e t , segundo Farias e Laurencel (2015), é calculado pela fórmula de Laspeyres.

$$IPC_{t-1,t}^A = \sum_{m=1}^M W_{t-1}^m I_{t-1,t}^m$$

onde o peso W_{t-1}^m é o peso de cada subitem m , referente ao período $t - 1$ e $I_{t-1,t}^m$ é o índice de preços do item m entre os meses $t - 1$ e t , para $t \geq 2$, calculados com base nas três pesquisas citadas.

O subitem é a menor unidade de ponderação dentre as estruturas de ponderação (grupo, sub-grupo, item e subitem) descritas na Série de Relatórios Metodológicos do IBGE (IBGE, 2006). Ao todo, o IPCA mede as variações de preços de 465 subitens alocados nos grupos: alimentação e bebidas; habitação; artigos de residência; vestuário; transportes; saúde e cuidados pessoais; despesas pessoais; educação e comunicação.

1.2 A Inflação

A inflação é um fenômeno monetário que consiste no aumento dos preços praticados na economia de mercado. Na literatura, há três classificações para os processos inflacionários:

- Inflação por demanda
- Inflação de custos
- Inflação inercial

A **inflação de demanda** se baliza no excesso de demanda aliado à pouca oferta. De acordo com Luque e Vanconcellos (2002), o excesso de demanda agregada supera a oferta, em geral, quando há um aumento substancial no poder aquisitivo.

A **inflação de custos** está associada ao reflexo do aumento no preço dos insumos necessários para a produção de bens e serviços. Nesse caso, o custo de produção é repassado para o custo do produto final. Para Serigati e Possamai (2014), por exemplo, a inflação de custos no Brasil seria resultado da elevação progressiva do custo de produção das *commodities*, matérias-primas de diversas cadeias produtivas.

O conceito da inflação inercial leva em conta os dois conceitos anteriores. Em 1984, Lopes (1984) apresenta teorias e conceitos que comprovam a inflação inercial no âmbito nacional. Segundo o autor, a **inflação inercial** é aquela que resulta das especulações acerca do desenvolvimento econômico futuro.

Após o impacto de um processo inflacionário, é comum a manutenção do aumento sistemático de preços. No entanto, essa prática não só contribui para um novo processo, como também implica na resistência dos indicadores aos efeitos das políticas de estabilização e de retomada. Para combater a inflação, em 21 de junho de 1999 (Decreto 3.088), foi estabelecida a sistemática de “metas para a inflação”, em que a inflação é representada por variações anuais de um índice de preços de ampla divulgação, o sistema tem como finalidade direcionar a fixação do regime de política monetária e, como resultado, amenizar os efeitos de processos inflacionários.

Em 30 de junho de 1999, a Resolução 2.615 do CMN determinou que o índice adotado para os fins do Decreto 3.088 seria o IPCA calculado pelo IBGE. Desde então, o IPCA é o índice utilizado pelo Banco Central do Brasil para o acompanhamento dos objetivos estabelecidos no sistema de metas, sendo, portanto, considerado o índice oficial de inflação do país.

Consequentemente, o estudo de seu comportamento histórico revela-se de grande importância, uma vez que o índice foi escolhido pelo CMN para balizar a política monetária do Brasil. A Tabela 2 apresenta o histórico de metas estabelecidas pelo governo para a inflação do Brasil, desde que o sistema de metas foi instituído em 1999. A inflação efetiva, medida pelo IPCA acumulado em cada ano, esteve 4 vezes acima do limite superior de tolerância, nos anos de 2001, 2002, 2003 e 2015. O maior intervalo de tolerância foi de 5% observado em 2003 (Resolução 2.972), em 2004 (Resolução 3.108) e em 2005.

Tabela 2: Histórico de Metas para a Inflação no Brasil

Ano	Norma	Data	Meta	Banda	Limites	Inflação Efetiva
1999			8,00	2	6 a 10	8,94
2000	Resolução 2.615	30/06/1999	6,00	2	4 a 8	5,97
2001			4,00	2	2 a 6	7,67
2002	Resolução 2.744	28/06/2000	3,50	2	1,5 a 5,5	12,53
2003	Resolução 2.842/2.972	28/06/2001	3,25	2	1,25 a 5,25 e 1,5 a 6,5	9,3
		27/06/2002	4,00	2,5		
2004	Resolução 2.972/3.108	27/06/2002	3,75	2,5	1,5 a 6,25 e 3 a 8	7,6
		25/06/2003	5,50	2,5		
2005	Resolução 3.108	25/06/2003	4,50	2,5	2 a 7	5,69
2006	Resolução 3.210	30/06/2004	4,50	2	2,5 a 6,5	3,14
2007	Resolução 3.291	23/06/2005	4,50	2	2,5 a 6,5	4,46
2008	Resolução 3.378	29/06/2006	4,50	2	2,5 a 6,5	5,9
2009	Resolução 3.463	26/06/2007	4,50	2	2,5 a 6,5	4,31
2010	Resolução 3.584	01/07/2008	4,50	2	2,5 a 6,5	5,91
2011	Resolução 3.748	30/06/2009	4,50	2	2,5 a 6,5	6,5
2012	Resolução 3.880	22/06/2010	4,50	2	2,5 a 6,5	5,84
2013	Resolução 3.991	30/06/2011	4,50	2	2,5 a 6,5	5,91
2014	Resolução 4.095	28/06/2012	4,50	2	2,5 a 6,5	6,41
2015	Resolução 4.237	28/06/2013	4,50	2	2,5 a 6,5	10,67
2016	Resolução 4.345	25/06/2014	4,50	2	2,5 a 6,5	6,29
2017	Resolução 4.419	25/06/2015	4,50	1,5	3 a 6,0	
2018	Resolução 4.499	30/06/2016	4,50	1,5	3 a 6,0	
2019	Resolução 4.582	29/06/2017	4,25	1,5	2,75 a 5,75	
2020	Resolução 4.582	29/07/2017	4,00	1,5	2,5 a 5,5	

Fonte: Site do BCB <http://www.bcb.gov.br/Pec/metas/TabelaMetaseResultados.pdf>.

Ao CMN foi atribuída a competência para fixar as metas e os limites de tolerância e ao Banco Central a função de assegurar o cumprimento da meta para a taxa de variação do IPCA acumulado estipulada para o ano corrente, mais especificamente, a cargo do Comitê de Política Monetária do Banco Central (COPOM). Para tanto, o COPOM utiliza a variação da taxa SELIC como instrumento para possibilitar o cumprimento da meta inflacionária.

No Brasil, por exemplo, durante a Grande Recessão Mundial de 2008, que se originou no setor hipotecário dos EUA, o governo aprovou diversas medidas para impulsionar a economia e minimizar os efeitos da turbulência dos mercados de comércio internacional. Apesar do período de grande crescimento, a política de expansão contribuiu para o aumento de preços. A isenção de impostos, o crédito abundante e os empréstimos a consumidores reforçaram o poder de compra dos brasileiros. Por conseguinte, o aumento da demanda no mercado local fez com que o IPCA subisse de 4,7% em setembro de 2010 para

7,3% em setembro de 2011 (IBGE, 2015). Posteriormente, cortar gastos para equilibrar as contas públicas tornou-se um dos grandes desafios do governo.

Em abril de 2015, especialistas do Fundo Monetário Internacional (FMI) acreditavam que o futuro do Brasil estava ameaçado. De fato, os indicadores publicados no Relatório IV N°15/167 do fundo evidenciaram a recessão esperada para 2015, a previsão econômica era de redução na produção nacional de cerca de 1% do Produto Interno Bruto (PIB) com taxas de inflação de 7% acumulada ao ano (FMI, 2015). O pacote adotado pelo governo federal em março de 2015 foi notícia no diário internacional *The Wall Street Journal*, “Brazil’s Dilma Rousseff Defends Austerity Measures in TV Address”, Trevisani and Jelmayer (2015). O jornal noticiou que o Brasil enfrentava o risco de rebaixamento na classificação das agências americanas de classificação de risco de investimentos, o que, posteriormente, ocorreu.

Desde então, uma série de medidas de ajuste econômico foram adotadas pelo governo brasileiro, destacando-se os cortes na taxa SELIC. Nesse sentido, o Boletim de Expectativas de N° 37 presente na Carta de Conjuntura do IPEA informa que, no último trimestre de 2015, a taxa de inflação (IPCA) esperada para doze meses era de 7,0% a 9,0% e caiu ao longo de 2016 e 2017 para 4,0% a 4,5%. No cenário atual, percebe-se indícios que o país vive melhores perspectivas econômicas, com expectativas positivas, especialmente, devido a um cenário de inflação menor e juros em queda. Esses fatores contribuem para incentivar investimentos e, conseqüentemente, criar uma atmosfera favorável para o aumento da renda e do emprego para os brasileiros. O Banco Central tem feito cortes contínuos nos juros básicos da economia (SELIC), esse fato pode ser confirmado pela leitura dos comunicados mais recentes das decisões do COPOM disponíveis no site do banco Central (<http://www.bcb.gov.br/pt-br/#!/t/copomcomunicados>).

1.3 Métodos para Previsão da Inflação

Em 1958, o neozelandês Willian Phillips (1958) propôs um modelo empírico macroeconômico de equação única, que ficou conhecido como Curva de Phillips, descrevendo uma relação inversa histórica entre taxas de desemprego e taxas de inflação correspondentes. No Brasil, Arruda et. al. (2011) compararam previsões para a taxa de inflação mensal brasileira (IPCA acumulado mensal) a partir de diferentes modelos lineares e não lineares de séries temporais, da Curva de Phillips e modelos vetoriais, e concluiu que o menor erro de previsão encontrado foi a partir da curva de Phillips ampliada.

Em 1969, os economistas britânicos John Bates e Clive Granger (1969) propuseram que a combinação de previsões é caracterizada pelo aumento da precisão de prognósticos decorrente da complementaridade da informação contida nas previsões individuais. No Brasil, Marques (2005) afirma que apesar dos ganhos da combinação serem limitados, há baixos riscos associados ao se incorporar previsões de diferentes índices de preços frente aos ganhos de informação.

Na análise de séries temporais, o método Box-Jenkins ficou conhecido após os estatísticos George Box e Gwilym Jenkins aplicarem modelos de média móvel autoregressiva (ARMA) ou média móvel autoregressiva integrada (ARIMA). Meyler et. al.(1998) consideraram em seu artigo a média móvel integrada autorregressiva (ARIMA) para prever a inflação e concluíram que os modelos ARIMA são teoricamente justificados, pois verificou-se média e variância da série constantes, e podem ser surpreendentemente robustos se comparados à modelagens multivariadas.

Na Inglaterra no ano de 1982, os modelos de heterocedasticidade condicional (ARCH) foram introduzidos por Engle na tentativa de caracterizar a inflação dos salários na Grã-Bretanha. Os modelos ARCH e suas derivações supõem que os retornos (diferença entre o valor atual e o valor imediatamente passado) são não-correlacionados. No entanto, a variância dos retornos atuais depende dos retornos passados por meio de uma função quadrática, essa abordagem exhibe agrupamento de volatilidade em função do tempo, ou seja, períodos de grande instabilidade intercalados com períodos de relativa estabilidade.

Nos Estados Unidos, Nakamura (2005) avaliou a utilidade de aplicações de redes neurais a modelos previsão macroeconômica. Segundo a pesquisadora as redes neurais funcionam bem em relação aos modelos AR para horizontes de um e dois trimestres no conjunto de testes da inflação americana de 1978 a 2002. Os resultados sugerem que o procedimento de paragem precoce contribui consideravelmente para o sucesso preditivo da abordagem e deve ser incorporado em futuros experimentos de previsão envolvendo redes neurais. Além disso, as redes não devem ser ignoradas quando há poucos dados observados, como é o caso de muitas variáveis macroeconômicas.

Em 2005, Valle (2005) usou modelos dinâmicos de primeira ordem para modelar a volatilidade estocástica e concluiu que o métodos usados tem a vantagem de fornecer a distribuição de variáveis latentes e de qualquer função destas. Estas estimativas podem ser usadas nas diferentes áreas das finanças modernas. O autor propõe uma extensão multivariada para o modelo resultante e a implementação Bayesiana para pares de ativos, proporcionando melhores estimativas para as volatilidades.

No Brasil, Oliveira e Andrade (2010) mostraram que, de um modo geral, a abordagem Bayesiana fornece estimativas satisfatórias. Foi feita uma reparametrização dos modelos estudados e adotada distribuição a priori não-informativa sendo capaz de obter uma convergência mais rápida do processo de inferência de parâmetros de modelos da família ARCH com Métodos de Monte Carlo via Cadeias de Markov.

2 Objetivos

O objetivo geral deste trabalho é extrair inferências de séries temporais e avaliar a capacidade de preditiva dos modelos com relação ao IPCA, considerando a abordagem clássica de Box-Jenkins. Para tanto, foram estabelecidos os seguintes objetivos específicos:

1. Selecionar modelos teóricos para representar os dados,
2. Estimar os modelos através de seus parâmetros, verificar a qualidade dos ajustes e usar os modelo ajustados para melhor compreensão da série,
3. Prever valores futuros da série, através desses modelos de junho de 2016 a novembro de 2017.
4. Comparar a previsão dos modelos e verificar a existência de um melhor modelo com base nas medidas de erro de estimação.

3 Materiais e Métodos

Inicialmente, foi considerada a série histórica de janeiro de 1994 a dezembro de 2017, no entanto, as oscilações do índice imediatamente após o período de implantação do Plano Real trazem prejuízos à suposição de estacionariedade da série temporal presente na abordagem de Box-Jenkins. Então, será estudada a série histórica referente a 217 observações do IPCA, de dezembro de 1999 a novembro de 2017, período que vigora o sistema de metas. Sendo que, as observações de junho de 2016 em diante foram usadas no cálculo do erro de predição e, portanto, não foram incluídas no processo de identificação do modelos e estimação de seus coeficientes.

3.1 A Série Histórica

O valor do IPCA acumulado em dezembro de 1999 foi o primeiro valor do IPCA utilizado como referência para a inflação efetiva anual (Tabela2). Os dados secundários foram obtidos no site do Instituto Brasileiro de Geografia e Estatística (IBGE), através do Sistema IBGE de Recuperação Automática (SIDRA), a produção do índice é mensal e provém de pesquisas observacionais de caráter longitudinal (POF, PLC e PEPS).

3.2 Metodologia

Nesta seção, serão apresentados os métodos descritivos e inferenciais para identificação de tendência e caracterização da sazonalidade da série em estudo, critérios de identificação pela abordagem Box-Jenkins, algoritmos de estimação e previsão e conceitos básicos de séries temporais. O nível de significância adotado neste trabalho foi de 5%.

3.2.1 Conceitos Básicos

Nesta subseção, serão abordados alguns dos conceitos necessários para análise de séries temporais.

Definição 3.2.1 *O processo estocástico é uma família de variáveis aleatórias definidas num mesmo espaço de probabilidade (Ω, F, P) . Denota-se $Z(t, \omega)$ variável aleatória com dois argumentos, $t \in T$ e $\omega \in \Omega$. Para cada $\omega \in \Omega$ fixado, tem-se uma função de t , uma realização do processo ou ainda uma série temporal.*

Seja T um conjunto arbitrário. Um processo estocástico é uma família $Z = \{Z(t), t \in T\}$, tal que, para cada $t \in T$, $Z(t)$ é uma variável aleatória.




Figura 1: Processo Estocástico representado como família de variáveis aleatórias.

Definição 3.2.2 *Série temporal ou trajetória do processo é um conjunto de observações $z_t, t \in T$ amostradas em um tempo t . No presente estudo, o conjunto de tempos de observações T é formado por pontos discretos, igualmente espaçados e, sem perda de generalidade, assume-se que $T \subset \mathbb{Z}$.*

Definição 3.2.3 *A sequência aleatória independente e identicamente distribuída $\{\varepsilon_t, t \in \mathbb{Z}\}$ é um Ruído Branco se $Cov\{\varepsilon_t, \varepsilon_s\} = 0, t \neq s$. Na qual,*

$$E(\varepsilon_t) = \mu_\varepsilon$$

$$Var(\varepsilon_t) = \sigma_\varepsilon^2$$

$$\gamma_k = Cov\{\varepsilon_t, \varepsilon_{s=t+k}\} = \begin{cases} \sigma^2, & \text{se } k = 0 \\ 0, & \text{se } k \neq 0, \quad \forall t \geq 1 \end{cases}$$

Notação $\varepsilon_t \sim RB(\mu, \sigma^2)$.

O Ruído Branco Gaussiano é um ruído cuja função densidade de probabilidade (f.d.p.) segue distribuição normal com média μ e variância σ^2 $\varepsilon_t \sim N(\mu, \sigma_\varepsilon^2)$.

O modelo de decomposição aditiva com as seguintes componentes não observáveis foi escolhido para representar as componentes do processo estocástico Z_t .

$$Z_t = T_t + S_t + \varepsilon_t$$

Em que, T_t e S_t representam tendência e sazonalidade e ε_t é a componente que representa o erro aleatório. De acordo com Brockwell e Davis (2013), são considerados como tendência os movimentos de longo prazo que impactam a média $E[Z_t] = \mu_t$ e como sazonais os eventos cíclicos relacionados ao calendário. Segundo Morettin e Toloi (2006) observa-se em séries sazonais relações entre as observações dos meses de um ano particular ou entre observações do mesmo mês em anos sucessivos.

Considere o conjunto finito de variáveis aleatórias do processo estocástico $\{Z(t, \omega) \mid \omega \in \Omega, t \in T\}$, onde T é um conjunto de pontos igualmente espaçados, então a função de distribuição conjunta n-dimensional de Z_{t1}, \dots, Z_{tn} é dada por:

$$F_{Z_{t1}, Z_{t2}, \dots, Z_{tn}}(z_1, \dots, z_n) = P(\{\omega \in \Omega \mid Z(\omega, t1) \leq z_1, Z(\omega, t2) \leq z_2, \dots, Z(\omega, tn) \leq z_n\}) \quad (3.1)$$

para quaisquer t_1, t_2, \dots, t_n, k de T .

Definição 3.2.4 *Um processo estocástico $\{Z_t, t \in T\}$ é estacionário em Distribuição de ordem n se*

$$F_{Z_{t1+k}, \dots, Z_{tn+k}}(z_1, \dots, z_n) = F_{Z_{t1}, \dots, Z_{tn}}(z_1, \dots, z_n)$$

Definição 3.2.5 *Um processo estocástico $\{Z_t, t \in T\}$ é estritamente ou fortemente estacionário se o processo é estacionário de ordem n, $\forall n \in \mathbb{Z}$. Isto é, todas as distribuições finito-dimensionais (3.5) são invariantes sob translações no tempo, com isso, a média*

$\mu(t) = \mu$ e a variância $V(t) = \sigma^2$ são constantes.

$$F_{Z_{t_1+k}, \dots, Z_{t_n+k}}(z_1, \dots, z_n) = F_{Z_{t_1}, \dots, Z_{t_n}}(z_1, \dots, z_n), \quad \forall n \in \mathbb{Z} \quad (3.2)$$

Supõe-se, sem perda de generalidade, que $\mu = 0$, caso contrário considera-se o processo $\{Z(t) - \mu\}$.

Definição 3.2.6 *Um processo estocástico $\{Z_t, t \in T\}$ diz-se fracamente estacionário ou estacionário de segunda ordem se e somente se*

- (i) $E\{Z(t)\} = \mu(t) = \mu, \quad \forall t \in T$
- (ii) $E\{Z^2(t)\} < \infty, \quad \forall t \in T$
- (iii) $\gamma(|t_1 - t_2|) = \text{Cov}\{Z(t_1), Z(t_2)\}$ é função apenas de $|t_1 - t_2|$

Isto é, se $\{Z(t)\}$ é um processo estacionário em distribuição de ordem 2, então $\{Z(t)\}$ é fracamente estacionário (Brockwell e Davis, 2013). Dado $h = t_2 - t_1$, $\gamma(h)$ é chamada função de autocovariância (FACV), $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$ é chamada de função de autocorrelação (FAC) e h é chamado de defasagem.

3.2.2 Função de Autocovariância

Seja $\{X_t, t \in \mathbb{Z}\}$ um processo estacionário real discreto, de média zero e função de autocovariância (FACV) denotada por $\gamma_k = \text{Cov}\{Z_t, Z_{t+k}\} = E\{X_t X_{t+k}\}$.

Proposição 3.2.7 *A FACV γ_k satisfaz as seguintes propriedades:*

- (i) $\gamma_0 > 0$,
- (ii) $\gamma_{-k} = \gamma_k$
- (iii) $|\gamma_k| \leq \gamma_0, \forall k \in \mathbb{Z}$ e
- (iv) para quaisquer valores $t_1, t_2, \dots, t_n \in T$, tem-se que

$$\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \gamma(|t_i - t_j|) \geq 0,$$

em que $\alpha_1, \alpha_2, \dots, \alpha_n$ são constantes reais.

Note que se $k = 0$ então $\gamma_0 = \text{Cov}\{Z_t, Z_{t+k}\} = E\{Z_t Z_t\} = E\{Z_t^2\} = \text{Var}\{Z_t\}$. A FACV amostral: $\hat{\gamma}(k) = \frac{1}{n} \sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})$.

3.2.3 Função de Autocorrelação e Função de Autocorrelação Parcial

Seja $\{X_t, t \in \mathbb{Z}\}$ um processo estacionário e função de autocorrelação (FAC) denotada por $\rho_k = \text{Corr}\{Z_t, Z_t + k\} = \frac{\gamma(|t+k-t|)}{\sqrt{\gamma_0}\sqrt{\gamma_0}} = \frac{\gamma_k}{\gamma_0}$.

Proposição 3.2.8 *A FAC ρ_k satisfaz as seguintes propriedades:*

- (i) $\rho_0 = 1$,
- (ii) $\rho_{-k} = \rho_k$,
- (iii) $|\rho_k| \leq 1, \forall k \in \mathbb{Z}$ e
- (iv) para quaisquer valores $t_1, t_2, \dots, t_n \in T$, temos que

$$\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \rho(|t_i - t_j|) \geq 0,$$

em que $\alpha_1, \alpha_2, \dots, \alpha_n$ são constantes reais.

A FAC amostral: $\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}$, junto com a função de autocorrelação parcial (FACP) amostral, é usada na identificação dos processos lineares do tipo ARIMA. O gráfico de autocorrelação, ou correlograma, é composto por valores de autocorrelação amostral para as defasagens $k \in \mathbb{Z}$ que são exibidos apenas para valores não negativos de lag h devido à propriedade (ii) da FAC.

As propriedades (iv) de FAC e FACV implicam que

$$\text{Var}\{(Z_1, Z_2, \dots, Z_t)^T\} = \begin{bmatrix} \gamma(0) & \gamma(1) & \gamma(2) & \dots & \gamma(k-1) & \gamma(k) \\ \gamma(1) & \gamma(0) & & & & \gamma(k-1) \\ \vdots & \vdots & & & \vdots & \vdots \\ \gamma(0) & & & & \gamma(0) & \\ \gamma(k) & \gamma(k-1) & \gamma(k-2) & \dots & \gamma(1) & \gamma(0) \end{bmatrix}$$

$$Corr\{(Z_1, Z_2, \dots, Z_t)^T\} = \begin{bmatrix} \rho(0) & \rho(1) & \rho(2) & \dots & \rho(k-1) & \rho(k) \\ \rho(1) & \rho(0) & & & & \rho(k-1) \\ \vdots & \vdots & & & \vdots & \vdots \\ \rho(0) & & & & \rho(0) & \\ \rho(k) & \rho(k-1) & \gamma(k-2) & \dots & \rho(1) & \rho(0) \end{bmatrix}$$

são semi-definidas positiva.

Considere o modelo autoregressivo de ordem k descrito por $X_t = \phi_{k1}X_{t-1} + \phi_{k2}X_{t-2} + \dots + \phi_{kk}X_{t-k} + \varepsilon_t$, então $\phi_{k1}, \dots, \phi_{kk}$ é solução de

$$\begin{cases} \rho(1) = \phi_{k1} + \phi_{k2}\rho(1) + \phi_{k3}\rho(2) + \dots + \phi_{kk}\rho(k-1) \\ \rho(2) = \phi_{k1}\rho(1) + \phi_{k2} + \phi_{k3}\rho(1) + \dots + \phi_{kk}\rho(k-2) \\ \vdots \\ \rho(i) = \phi_{k1}\rho(i-1) + \phi_{k2}\rho(i-2) + \phi_{k3}\rho(i-3) + \dots + \phi_{kk}\rho(i-k) \\ \vdots \\ \rho(k) = \phi_{k1}\rho(k-1) + \phi_{k2}\rho(k-2) + \phi_{k3}\rho(k-3) + \dots + \phi_{kk} \end{cases}$$

Matricialmente,

$$\begin{bmatrix} \rho(1) \\ \rho(2) \\ \rho(3) \\ \vdots \\ \rho(k) \end{bmatrix} = \begin{bmatrix} 1 & \rho(1) & \rho(2) & \dots & \rho(k-1) \\ \rho(1) & 1 & \rho(1) & \dots & \rho(k-2) \\ \rho(2) & \rho(1) & 1 & \dots & \rho(k-3) \\ \vdots & \vdots & & \ddots & \vdots \\ \rho(k-1) & \rho(k-2) & \rho(k-3) & \dots & 1 \end{bmatrix} \begin{bmatrix} \phi_{k1} \\ \phi_{k2} \\ \phi_{k3} \\ \vdots \\ \phi_{kk} \end{bmatrix} \quad (3.3)$$

A autocorrelação parcial amostral $\hat{\phi}_{kk}$ é dada pela solução das equações:

$$\begin{cases} \hat{\phi}_{k1} + \hat{\phi}_{k2}\hat{\rho}(1) + \hat{\phi}_{k3}\hat{\rho}(2) + \dots + \hat{\phi}_{kk}\hat{\rho}(k-1) = \hat{\rho}(1) \\ \hat{\phi}_{k1}\hat{\rho}(1) + \hat{\phi}_{k2} + \hat{\phi}_{k3}\hat{\rho}(1) + \dots + \hat{\phi}_{kk}\hat{\rho}(k-2) = \hat{\rho}(2) \\ \vdots \\ \hat{\phi}_{k1}\hat{\rho}(i-1) + \hat{\phi}_{k2}\hat{\rho}(i-2) + \hat{\phi}_{k3}\hat{\rho}(i-3) + \dots + \hat{\phi}_{kk}\hat{\rho}(i-k) = \hat{\rho}(i) \\ \vdots \\ \hat{\phi}_{k1}\hat{\rho}(k-1) + \hat{\phi}_{k2}\hat{\rho}(k-2) + \hat{\phi}_{k3}\hat{\rho}(k-3) + \dots + \hat{\phi}_{kk} = \hat{\rho}(k) \end{cases}$$

3.2.4 Modelos Box-Jenkins

Os modelos ARMA, são casos particulares de um modelo de filtro linear.




Figura 2: Representação do Processo Linear. Fonte: Morettin e Toloi (2006)

$$Z_t = \mu + a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots = \mu + \psi(B)a_t$$

em que $\psi(B) = 1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \dots$, é denominada função de transferência de filtro. Em termos gerais, se a sequência de pesos $\{\psi_j, j \geq 1\}$ converge, então a série é estacionária. O processo linear é conhecido como $MA(\infty)$.

Teorema 3.2.9 *Pela decomposição de Wold prova-se que qualquer processo estacionário tem uma representação de médias móveis (MA).*

3.2.4.1 Causalidade e Invertibilidade

De acordo com Brockwell e Davis (2013), um processo estocástico Z_t é causal se

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p \neq 0, \forall |z| \leq 1 \quad (3.4)$$

e, invertível se

$$\theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q \neq 0, \forall |z| \leq 1 \quad (3.5)$$

Os autores ainda afirmam que um processo Z_t causal (3.4) independe do futuro, ou de forma mais concisa é um processo autorregressivo causal, expressável em termos dos valores passados $Z_{t-1}, Z_{t-2}, \dots, Z_{t-p}$. De modo similar, um processo invertível Z_t é expressável em termos dos choques aleatórios passados $a_{t-1}, a_{t-2}, \dots, a_{t-q}$. Ou seja, todo processo estacionário tem representação por médias móveis e, portanto, é causal com base no Teorema 3.2.9.

A principal suposição de um processo ARMA é a de estacionariedade garantida quando Z_t é causal e invertível. Considere o operador descrito por $B^j X_t = X_{t-j}$, então, um processo ARMA(p,q) é descrito por

$$\phi(B)Z_t = \theta(B)a_t$$

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$$

$$\theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$$

$\phi(B)$ e $\theta(B)$ são polinômios que satisfazem (3.7) e (3.8).

Em termos de previsão, tem-se que

$$\hat{Z}_t(h) = \phi_1[Z_{t+h-1}] + \dots + \phi_p[Z_{t+h-p}] - \theta_1[a_{t+h-q}] + [a_{t+h}] \quad (3.6)$$

Repare que para se obter \hat{Z}_t é necessário calcular $\hat{Z}_t(h-1)$ e $\hat{Z}_t(h-2)$, ..., o que ocorre, nesse caso, é que os últimos valores da série são usados como estimativa de \hat{Z}_t nos passos $h-1$, $h-2$,

3.2.4.2 Modelo Autoregressivo e de Médias Móveis Integrado - ARIMA

O modelo ARIMA é uma generalização da classe ARMA. Processos ARIMA são reduzidos a processos ARMA quando diferenciados finitamente muitas vezes. Segundo Moret-tin e Toloi (2006), a representação por equações de diferenças é a forma mais usual e útil para calcular previsões, logo foi a escolhida para representar os modelos ARIMA(p,d,q), em que o coeficiente d representa o números de diferenciações .

$$Z_t = \varphi_1 Z_{t-1} + \varphi_2 Z_{t-2} + \dots + \varphi_{p+d} Z_{t-p-d} + a_t - \theta_1 a_{t-1} \dots - \theta_q a_{t-q}$$

onde $\varphi(B) = 1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_{p+d} B^{p+d}$ e $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^{t-q}$.

Z_t pode ser reescrito como $\varphi(B)Z_t = \theta(B)a_t$,

$$\varphi(B)Z_t = \phi(B)\Delta^d = \phi(B)(1 - B)^d.$$

3.2.4.3 Modelo ARIMA Sazonal - SARIMA

Modelos SARIMA(p,d,q)(P,D,Q)₁₂ são modelos ARIMA sazonais multiplicativos descritos por

$$\phi(B)\Phi(B^{12})(1 - B^{12})^D(1 - B)^d Z_t = \theta(B)\Theta(B^{12})a_t$$

$$\phi(B)\Phi(B^{12})\Delta^d \Delta_{12}^D Z_t = \theta(B)\Theta(B^{12})a_t$$

$$\Phi(B^{12}) = 1 - \Phi_1 B^{12} - \dots - \Phi_P B^{12P},$$

$$\Theta(B^{12}) = 1 - \Theta_1 B^{12} + \dots + \Theta_Q B^{12Q},$$

$\Delta^d = (1 - B)^d$ é o operador diferença, d indica o número de diferenças e

$\Delta_{12}^D = (1 - B^{12})^D$ é o operador diferença sazonal, D indica o número de diferenças.

Isto implica que deve-se tomar a d diferenças simples e D diferenças sazonais de modo que $W_t = \Delta^d \Delta_{12}^D Z_t$. Após diferenciado $d + D$ vezes o processo é estacionário, então faz-se previsões de modo análogo ao modelo ARMA.

3.2.5 Busca Iterativa do Melhor Modelo

O método original Box-Jenkins usa uma abordagem iterativa de modelagem em três estágios:

1. Identificação do modelo e seleção do modelo: certificando-se de que as variáveis são estacionárias, identificando a sazonalidade na série (diferenciando-a sazonalmente se necessário) e usando gráficos da autocorrelação e funções de autocorrelação parcial das séries temporais dependentes para decidir quais (se houver) são os componentes autorregressivos ou de médias móveis que devem ser usado no modelo.
2. Estimativa de parâmetros usando algoritmos de computação para chegar aos coeficientes que melhor se adequam ao modelo SARIMA selecionado.
3. Verificação do modelo testando se o modelo estimado está em conformidade com as especificações de um processo univariado estacionário. Em particular, os resíduos devem ser independentes uns dos outros e constantes em média e variância ao longo do tempo. (Traçar a média e a variância dos resíduos ao longo do tempo e realizar um teste de Ljung-Box ou autocorrelação de gráficos e autocorrelação parcial dos resíduos são úteis para identificar a falta de especificação.) Se a estimativa for inadequada, retornar ao primeiro passo e tentar construir um modelo melhor.

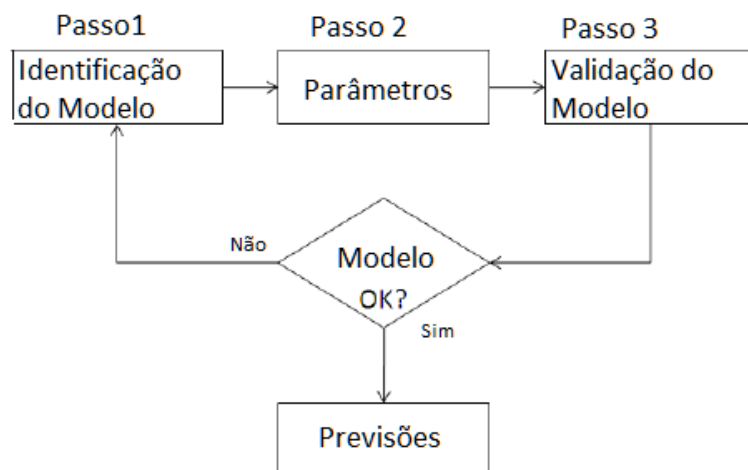


Figura 3: Metodologia Box-Jenkins. Fonte: Martinez (2015)

3.2.5.1 Identificação de Modelos

A identificação de modelos ARMA é feita com base na FAC e FACP amostrais usando os critérios descritos na Tabela 3 a seguir. No entanto, é necessário verificar primeiro se a série satisfaz a suposição de estacionariedade utilizando o teste de Dickey-Fuller (Dickey e Fuller, 1979).

Considere o processo autoregressivo de ordem 1 descrito por

$$\nabla X_t - \mu = \phi_0 * + \phi_1^* X_{t-1} + \varepsilon_t$$

Com $\nabla X_t - \mu = X_t - X_{t-1}$, $\phi_0^* = \mu(1 - \phi)$ e $\phi_1^* = \phi_1 - 1$.

$$\begin{cases} H_0 : \phi = 0 \text{ (É estacionária)} \\ H_1 : \phi < 0 \text{ (Não é estacionária)} \end{cases}$$

Seja $(\hat{\phi}_0^*, \hat{\phi}_1^*)$ o ponto de máximo de $S(\hat{\phi}_2^*, \hat{\phi}_1^*) = \sum_{t=2}^n (\nabla X_t - \phi_0^* - \phi_1^* X_{t-1})^2$. $DP(\phi_1^*) = \frac{\sum_{t=2}^n (\nabla X_t - \phi_0^* - \phi_1^* X_{t-1})}{(n-3)(\sum_{t=2}^n (X_{t-1} - \bar{X}))^{1/2}}$ em que $\bar{x} = \frac{1}{n-1} \sum_{t=1}^{n-1} X_t$.

Sob H_0 $\hat{\tau} = \frac{\hat{\phi}_1^*}{DP(\hat{\phi}_1^*)}$ tem distribuição assintótica com $P[\hat{\tau} < -1,95] = 0,05$, rejeita-se H_0 se τ for menor que o valor crítico. O teste será utilizado para verificar a hipótese de estacionariedade da série do IPCA e, uma vez que os dados são estacionários o processo de identificação do modelo é feito.

A Tabela 3 apresenta a regra de identificação dos modelos do tipo ARMA. Caso o decaimento exponencial não seja identificado em FAC ou FACP, usa-se os critérios de comparação de modelos AIC ou BIC da sub-seção 3.2.7.1.

Tabela 3: Comportamento característico da FAC e FACP (Identificação)

Modelo	Autocorrelação (FAC)	Autocorrelação parcial (FACP)
AR(p)	Dcaimento exponencial.	$\phi_{kk} = 0$ se $k > p$
MA(q)	$\rho(k = 0)$ se $k > q$	Dcaimento exponencial.
ARMA(p,q)	Dcaimento exponencial após $(q - p)$	Dcaimento exponencial após $(p - q)$

O decaimento exponencial lento da FAC ou FACP sugere uma ou mais diferenciações, a cada diferenciação os dados serão transformados, logo, haverá uma nova estimativa para FAC e FACP amostrais e uma nova etapa de identificação.

No caso de modelos sazonais, a identificação dos coeficientes da parte não-sazonal p e q é feita de acordo com os mesmos critérios citados Tabela 3. Já a identificação da parte que denota a sazonalidade estocástica é diferente e está representada na Tabela 4 que

mostra o comportamento característico da FAC e FACP quanto a regra de identificação para os coeficientes P e Q de um SARIMA.

Tabela 4: Comportamento característico da FAC e FACP para ajustes sazonais (Identificação)

Modelo	FAC*	FACP*
$AR(p)_s$	decai nas defasagens ks	zero após a defasagem Ps
$MA(q)_s$	zero após a defasagem Qs	decai nas defasagens ks
$ARMA(p, q)_s$	decai nas defasagens ks	decai nas defasagens ks

*Identificação com relação aos coeficientes sazonais P e Q.

No presente estudo, o lag considerado sazonal é $h = k12$, uma vez que a sazonalidade estudada é de $s = 12$, $k \in \mathbb{Z}$.

3.2.5.2 Estimação (método dos momentos): equações de Yule-Walker

Considere o modelo descrito por $X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \epsilon_t$, então $\hat{\phi}_1, \dots, \hat{\phi}_p$ é solução de

$$\begin{cases} \hat{\phi}_1 + \hat{\phi}_2 \hat{\rho}(1) + \hat{\phi}_3 \hat{\rho}(2) + \dots + \hat{\phi}_p \hat{\rho}(p-1) = \hat{\rho}(1) \\ \hat{\phi}_1 \hat{\rho}(1) + \hat{\phi}_2 + \hat{\phi}_3 \hat{\rho}(1) + \dots + \hat{\phi}_p \hat{\rho}(p-2) = \hat{\rho}(2) \\ \vdots \\ \hat{\phi}_1 \hat{\rho}(i-1) + \hat{\phi}_2 \hat{\rho}(i-2) + \hat{\phi}_3 \hat{\rho}(i-3) + \dots + \hat{\phi}_p \hat{\rho}(i-p) = \hat{\rho}(i) \\ \vdots \\ \hat{\phi}_1 \hat{\rho}(p-1) + \hat{\phi}_2 \hat{\rho}(p-2) + \hat{\phi}_3 \hat{\rho}(p-3) + \dots + \hat{\phi}_p = \hat{\rho}(p) \end{cases}$$

Propriedades:

- $\phi(z) = 1 - \hat{\phi}_1 z - \hat{\phi}_2 z^2 - \dots - \hat{\phi}_p z^p$ se $|z| \leq 1$;
- $\gamma(k) - \hat{\phi}_1 \hat{\gamma}(k-1) - \dots - \hat{\phi}_p \hat{\gamma}(k-p) = \begin{cases} 0, & |k| > 1 \\ \sigma^2, & |k| = 0 \end{cases}$;
- Para n suficientemente grande,

$$\hat{\phi}_p = (\hat{\phi}_1, \dots, \hat{\phi}_p)^\top \sim N\left(0, a_{ii} = \frac{\sigma^2 \Gamma_p^{-1}}{n}\right);$$

- Intervalo de confiança para $\phi_i, i = 1, \dots, p$,

$$IC(\phi_i, 1 - \alpha) = \left(-z_\alpha \sqrt{a_{ii}} + \hat{\phi}_i; z_\alpha \sqrt{a_{ii}} + \hat{\phi}_i\right)$$

3.2.5.3 Análise dos Resíduos

Ao final da estimação é necessário verificar a qualidade do ajuste. Primeiro verifica-se visualmente o correlograma, a função da autocorrelação parcial e o gráfico do resíduo padronizado dado por

$$r_t = \frac{e_t}{\gamma_e(0)}$$

em que $\gamma_e(0)$ é a variância do resíduo $e_t, t = 1, \dots, T$. Para um ruído branco gaussiano, temos que

- $\hat{\rho}(k) \sim N\left(0, \frac{1}{n}\right)$ e um intervalo de confiança com confiança $1 - \alpha$ é $\left(\frac{-z_\alpha}{\sqrt{n}}; \frac{z_\alpha}{\sqrt{n}}\right)$ em que $P(Z > z_\alpha) = \frac{\alpha}{2}$;
- $\hat{\phi}(k) \sim N\left(0, \frac{1}{n}\right)$ e um intervalo de confiança com confiança $1 - \alpha$ é $\left(\frac{-z_\alpha}{\sqrt{n}}; \frac{z_\alpha}{\sqrt{n}}\right)$ em que $P(Z > z_\alpha) = \frac{\alpha}{2}$;

Em seguida, usa-se o Teste de Jarque-Bera proposto por Carlos Jarque e Anil Bera em 1980. Trata-se de uma ferramenta estatística que avalia a hipótese de normalidade. As hipóteses envolvidas nesse teste são:

$$\begin{cases} H_0 : \text{Os dados seguem distribuição normal} \\ H_1 : \text{Os dados não seguem distribuição normal} \end{cases}$$

Estatística de teste de Jarque-Bera:

$$JB = n \left(\frac{b_1^2}{6} + \frac{(b_2 - 3)^2}{24} \right) \sim \chi_2^2,$$

em que $b_1 = \frac{m_4}{m_2^2}$, $b_2 = \frac{m_3}{m_2^{\frac{3}{2}}}$, e $m_k = \sum_{i=1}^n \frac{(X_i - \bar{X})^k}{n}$.

O teste será utilizado para verificar a suposição de normalidade dos modelos SARIMA.

Uma alternativa ao teste de Jarque-Bera é o Teste de Shapiro-Wilk, as hipóteses são iguais e a estatística de teste é dada por

$$W = \frac{b^2}{s^2} = \frac{\left(\sum_{i=1}^n a_i y_i\right)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

onde y_i é a variável aleatória observada e a_i são coeficientes tabelados.

Primeiro, ordena-se as observações em ordem decrescente $y_1 \leq y_2 \leq \dots \leq y_n$, em seguida, calcula-se b^2 e s^2 .

Por fim, para testar a hipótese de independência entre os resíduos de uma série temporal, usa-se a estatística de Ljung-Box que testa se a FAC das defasagens 1,...,H são iguais a zero. O teste será utilizado para avaliar a autocorrelação residual dos ajustes dos modelos propostos.

$$\begin{cases} H_0 : \rho_1 = \rho_2 = \dots = \rho_H = 0 \\ H_1 : \text{Pelo menos um } \rho_k \neq 0, \quad k = 1, \dots, H \end{cases}$$

$$Q_H = n \cdot (n + 2) \sum_{h=1}^H \frac{\hat{\rho}_e^2(h)}{n - h} \sim \chi_{H-p-q}^2 \quad (3.7)$$

em que $e_t = x_t - \hat{x}_t$ é denominado resíduo, $\hat{\rho}_e(h), h = 1, \dots, H$ é a a FAC amostral do resíduo e n é o tamanho da série temporal. Rejeitamos H_0 ao nível de significância se o valor da estatística Q_H ultrapassa o quantil $1 - \alpha$ da distribuição χ_{H-p-q}^2 .

3.2.6 Testes para Identificação de Componentes

3.2.6.1 Testes de Wald-Wolfowitz para Tendência

De acordo com Morettin e Toloi (2006), seja $\{Z_t, t = 1, \dots, N\}$ uma série temporal com N observações. Atribui-se a cada valor de Z_t o símbolo “+”, se o valor observado z_t for maior ou igual a mediana de Z_t , e o símbolo “-” caso contrário. Logo, $N = (N_+ \text{ pontos “+”}) + (N_- \text{ pontos “-”})$. Desta forma, teremos grupos de observações marcadas com “+” e grupos de observações marcadas com “-” ao longo da série temporal. A contagem de grupos obtidos a partir de grupos consecutivos será a estatística do teste, isto é,

$T =$ “Contagem do número total de grupos com símbolos iguais consecutivos”.

$$\begin{cases} H_0 : \text{Os dados foram gerados de maneira aleatória (Não há tendência)} \\ H_1 : \text{Os dados não foram gerados de maneira aleatória (Há tendência)} \end{cases}$$

Rejeita-se H_0 se T for relativamente pequeno. Utiliza-se o Teorema Central do Limite para aproximar a distribuição de T por uma normal, isto é,

$$T \sim N \left(\frac{2N_+N_-}{N} + 1, \frac{2N_+N_-(2N_+N_- - N)}{N^2(N-1)} \right).$$

Dado o nível de significância, foi calculado o p -valor $= P[T > z_\alpha | H_0]$. O teste será utilizado para averiguar a presença de tendência.

3.2.6.2 Teste de Correlação de postos de Spearman para Tendência

Segundo Artusi et al. (2002), é possível testar a significância para o coeficiente de correlação de Spearman. O teste proposto tem as seguintes hipóteses.

$$\begin{cases} H_0 : r = 0 \text{ (Não há tendência)} \\ H_1 : r \neq 0 \text{ (Há tendência)} \end{cases}$$

A estatística de teste é dada por

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim T_{n-2}$$

Dado o nível de significância, foi calculado o p -valor $= P[|t| > |T_{\text{obs}}| | H_0] = 2P[T > |T_{\text{obs}}| | H_0]$. O teste será usado para verificar se o coeficiente de postos de Spearman entre

a variável z_t observada e o tempo genérico $t = 1, 2, 3, 4, \dots$ é significativo. Visto que o coeficiente $r \neq 0$ sabe-se o que os postos das variáveis observadas estão relacionados com a evolução do tempo t , em outras palavras, há tendência.

3.2.6.3 Análise de Variância para Sazonalidade

A análise de variância (ANOVA) será utilizada para comparação de médias, com o objetivo de encontrar diferenças entre os meses, considerando os anos como observações e meses os diferentes grupos. As hipóteses a serem testadas são

$$\begin{cases} H_0 : \mu_1 = \mu_2 = \mu_3 = \dots = \mu_k \\ H_1 : \text{Há ao menos um par em que } \mu_i \neq \mu_j, \forall i \neq j \end{cases}$$

no qual, μ_n é média do tratamento enésimo grupo.

Considere

$$SQ_{Ent} = \sum_{i=1}^k n_i \cdot (\bar{x}_i - \bar{x})^2$$

e

$$SQ_{Tot} = \sum_{i=1}^k \sum_{j=1}^{N_i} (x_i^j - \bar{x}_i)^2$$

. Com,

$$SQ_{Den} = SQ_{Tot} - SQ_{Ent}.$$

Tabela 5: Análise de Variância

Fonte de variação	Graus de liberdade	Média dos Quadrados	Valor de F
Entre grupos	$k - 1$	$\frac{SQ_{Ent}}{k - 1}$	$F = \frac{S_e^2}{S_d^2}$
Dentro dos grupos	$n - k$	$\frac{SQ_{Den}}{n - k}$	
Total	$n - 1$		

Usa-se $F \sim F_{g-1, n-g}$ para para testar H_0 , caso $F > f_{1-\alpha}$ rejeita-se a hipótese nula H_0 . Dado o nível de significância α , foi calculado o p-valor= $P(F \geq f_{1-\alpha})$.

3.2.6.4 Coeficiente de Assimetria

O coeficiente de assimetria permite caracterizar distribuições assimétricas. O valor negativo de A indica assimetria à esquerda, caso contrário, assimetria à direita. Um valor

próximo de zero indica que os valores são distribuídos de maneira relativamente igual com relação à média, ou seja, com uma distribuição aproximadamente simétrica.

$$A = \frac{Q_3 - Me}{Me - Q_1}.$$

Onde A é o coeficiente de assimetria, Q_3 é o terceiro quartil empírico, Me é a mediana dos dados e Q_1 é o primeiro quartil empírico.

3.2.7 Critérios de Comparação de Modelos

Dada uma coleção de modelos para os dados, os critérios para comparação de modelos estimam a qualidade de cada modelo em relação a cada um dos outros modelos. Assim, o Critério de Informação de Akaike (AIC) e o Critério de Informação Bayesiano (BIC) fornecem um meio para a seleção do modelo. Os critérios não avaliam a qualidade absoluta de um modelo, apenas a qualidade em relação a outros modelos, assim, quanto menor os valores dos critérios melhor é o ajuste e a previsão.

3.2.7.1 Critério de Informação de Akaike

O AIC foi proposto por Hirotugu Akaike (Akaike, 1998). Akaike, em seu artigo, sugere escolher o modelo, de modo que, L e M minimizem o critério abaixo.

$$\text{Akaike's Information Criterion: } AIC(L, M) = -2 \log(\hat{L}) + 2M.$$

Em que,

M - número de parâmetros.

L - função de verossimilhança em seu ponto de máximo.

3.2.7.2 Critério de Informação Bayesiano

Segundo Emiliano et. al (2010), “No caso de modelos de séries temporais, mesmo para amostras de tamanho pequeno (< 500), o desempenho dos critérios AIC e AIC Corrigido foram similares e inferiores ao BIC, para todos os modelos simulados. Assim para os casos em que foram simulados o uso do BIC para séries seria o mais indicado.”

$$\text{Bayesian Information Criterion: } -2 \log(\hat{L}) + \log(n)M.$$

3.2.7.3 Erro Absoluto Médio

Como o nome sugere, o Erro Absoluto Médio (MAE) é a média dos erros absolutos $|e_i| = |y_i - x_i|$.

$$\text{MAE} = \frac{\sum_{t=1}^n |y_t - x_t|}{n} = \frac{\sum_{t=1}^n |e_t|}{n}.$$

3.2.7.4 Erro Médio Percentual

O erro percentual médio (MPE) é a média calculada de erros percentuais pelos quais as estimativas ou previsões de um modelo diferem dos valores reais da quantidade prevista.

$$\text{MPE} = \frac{100}{n} \sum_{t=1}^n \frac{e_t}{y_t}$$

onde y_i é o valor real da quantidade que está sendo prevista ou estimada e n é o número de tempos diferentes.

3.2.7.5 Erro Médio Absoluto Percentual

O Erro Médio Absoluto Percentual (MAPE), é uma medida da precisão de estimação (ou previsão) de um método estatístico expressa como porcentagem absoluta.

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{e_t}{y_t} \right|,$$

3.2.7.6 Raiz do Erro Quadrático Médio

Se x_t é um vetor de n previsões e y_t é o vetor de valores observados da variável que está sendo prevista, então a Raiz Erro Quadrático Médio (RMSE) da amostra do preditor é computada como

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (e_t)^2}, \quad e_t = y_t - x_t.$$

Analogamente, para estimativas x_t é um vetor de estimativas.

3.2.8 Transformação de Box-Cox

A transformação Box-Cox é uma família de transformações indexadas por um parâmetro λ . Em séries temporais, se a variância muda com o tempo o processo não é estacionário, logo, é desejável transformar uma série temporal para torná-la estacionária. A modelagem Box-Jenkins é então usada para decidir se diferenciações ou diferenças sazonais serão úteis para remover tendências polinomiais ou tendências sazonais, respectivamente. Depois disso, se o diagnóstico confirmar as ordens p e q para o modelo ARMA, os parâmetros AR e MA podem então ser estimados. Considere Z_t a variável aleatória a ser transformada.

$$W_t(\lambda) = \begin{cases} \ln(Z_t), & \text{se } \lambda = 0, \\ \frac{(Z_t)^\lambda - 1}{\lambda}, & \text{se } \lambda \neq 0 \end{cases} \quad (3.8)$$

A transformação inversa é,

$$Z_t = \begin{cases} \exp(W_t(\lambda)), & \text{se } \lambda = 0, \\ (\lambda W_t + 1)^{1/\lambda}, & \text{se } \lambda \neq 0 \end{cases}. \quad (3.9)$$

4 Análise dos Resultados

Neste capítulo serão incluídos os resultados referentes às análises feitas sobre a série temporal do IPCA desde o plano real. Num primeiro momento, os resultados terão como principal objetivo selecionar modelos quanto à qualidade de ajuste aos dados e à adequação ao problema proposto.




Figura 4: Série histórica do IPCA de janeiro de 1994 a novembro de 2017.

A Figura 4 apresenta a série histórica dos valores observados do IPCA desde a implantação do plano real, de imediato, constata-se a não-estacionariedade dos dados já que a série não se desenvolve ao longo do tempo aleatoriamente em torno de uma média constante. Nos valores dos meses seguintes ao lançamento do real, as variações observadas são de até quatro dígitos, ao passo que, os valores mais atuais estão em torno de 4% acumulados no ano.

Sendo assim, serão estudados valores observados do IPCA desde dezembro de 1999, em concordância com a Tabela 2. O sistema de metas foi implementado em janeiro do mesmo ano, no entanto, apenas o valor do IPCA acumulado para o ano corrente, ou seja, dezembro, é utilizado para as diretrizes do sistema. Foram escolhidos 19 meses, de junho

de 2016 a novembro de 2017 para a amostra teste. Desse modo, os 198 valores do IPCA, de dezembro de 1999 até maio de 2016, foram usados na identificação do modelo e na estimação dos parâmetros. A Figura 5, apresenta os valores selecionados para amostra de treinamento, a linha vermelha representa a média amostral $\bar{Z}_t = \sum_{t=1}^{198} Z_t$ da série Z_t e os anos estão representados pelas sombras em verde.




Figura 5: Série histórica do IPCA acumulado por ano, de dezembro de 1999 a maio de 2016.

Com auxílio do software R, antes de caracterizar a série por meio de modelos autorregressivos univariados, foram promovidos alguns testes para verificar a presença de componentes não observáveis como a componente sazonal e de tendência, para esse tipo de abordagem supôs-se um modelo aditivo descrito na sub seção 3.2.1..

Os resultados dos testes para tendência foram apresentados na Tabela 6. Repare que, apesar das hipóteses serem semelhantes para o teste de Wald-Wolfowitz e para o teste do Coeficiente de Correlação de Spearman, as interpretações das estatísticas para cada teste de tendência são distintas e foram detalhadas nas subseções 3.2.6.1 e 3.2.6.2.

Tabela 6: Testes para tendência.

Teste para tendência	p-valor
Teste de Wald- Wolfowitz	$< 0,001$
Teste para o coeficiente de postos Spearman	0,011

Ambos testes rejeitam a hipótese nula da inexistência de tendência, isto é, a série não possui média constante e, portanto, não satisfaz a hipótese de estacionariedade. Também foi observado (Figura 5) que a discrepância entre os valores do IPCA nos anos de 2002 e 2003 e o restante da série sugere assimetria à direita na distribuição dos dados. Foi verificado que a distância entre o terceiro quartil empírico (7,51) e o valor de máximo (17,24) é expressiva e o valor da média amostral (6,82) é superior ao valor da mediana observada (6,38).

Os valores discrepantes são prejudiciais para estimação dos parâmetros do modelo. Observou-se que a inflação acumulada nos anos de 2002 e 2003 foi de 12,53% e 9,3%, respectivamente, e que a alta do índice da inflação, nesse período, está atrelada às incertezas com relação às eleições de 2002, na ocasião o ex-presidente Lula foi eleito. Nota-se que as flutuações do indicador estão intimamente relacionadas com variantes político-econômicas e expectativas com relação ao desenvolvimento econômico.

Pela abordagem 3.2.5, a identificação de modelos univariados que melhor representam os dados é feita pela análise das funções de autocorrelação e autorrelação parcial de um processo estacionário, ou seja, média, $E[Z_t] = \mu$, e, variância $V[Z_t] = \sigma^2$, constantes.

Foi, então, necessário transformar os dados para atender a suposição de estacionariedade e de normalidade. Segundo Souza e Camargo (1996), deve-se usar uma transformação não-linear da série observada de forma que a distribuição da série seja o mais próximo de uma distribuição normal.

A Tabela 7 apresenta os p-valores do teste de Shapiro-Wilk em função dos λ usados na transformação de Box-Cox 3.2.8, de -1 a 1, considerando apenas uma casa decimal para λ .

Tabela 7: Teste de shapiro-wilk para o IPCA transformado.

Lambda	p-valor	Lambda	p-valor
-1,0	< 0,0001	0,1	< 0,0001
-0,9	< 0,0001	0,2	< 0,0001
-0,8	< 0,0001	0,3	< 0,0001
-0,7	< 0,0001	0,4	< 0,0001
-0,6	< 0,0001	0,5	0,000213
-0,5	0,000213	0,6	0,000308
-0,4	0,000308	0,7	0,000277
-0,3	0,000277	0,8	0,000155
-0,2	0,000155	0,9	< 0,0001
-0,1	< 0,0001	1,0	< 0,0001
0,0	< 0,0001		

Os valores do p-valor do teste de normalidade de Shapiro-Wilk indicam que as transformações de Box-Cox para $\lambda = -0,4$ e $\lambda = 0,6$ são teoricamente as que melhor satisfazem a suposição de normalidade.

A Figura 6 apresenta o histograma das transformações Box-Cox com $\lambda = -0,4$ e $\lambda = 0,6$. Com base nos p-valores obtidos nos testes de Shapiro-Wilk da Tabela 7, foram comparados os histogramas das transformações que mais se aproximam da distribuição normal.

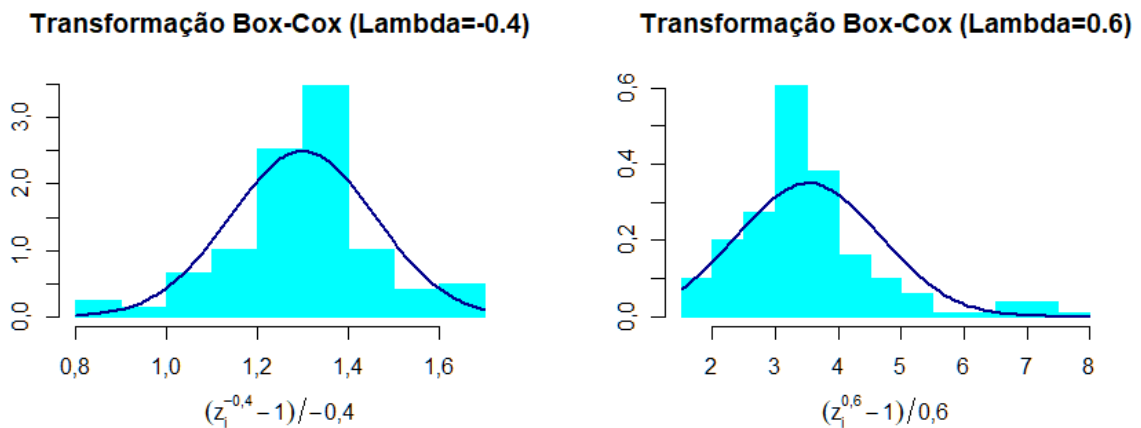


Figura 6: Histograma das transformações Box-Cox.

Considerando a Figura 6, foi calculado o coeficiente de assimetria para ambas transformações. Para $\lambda = -0,4$ tem-se $A_{-0,4} = -0,07964$ e, para $\lambda = 0,6$ tem-se $A_{0,6} = 1,3391$, conclui-se que a melhor transformação de Box-Cox para a série Z_t é $W_t(-0,4)$, Box-Cox com $\lambda = -0,4$.




Figura 7: Transformação Box-Cox com $\lambda = -0,4$.

Segundo Morettin e Toloi (2006), é importante considerar procedimentos de ajustamento sazonal em W_t e verificar se há sazonalidade determinística, ou seja, prevista diretamente por meses anteriores. Verificou-se pela Análise de Variância que a distribuição dos dados com relação aos meses é semelhante. O p -valor obtido na comparação de médias da ANOVA foi de aproximadamente 1. Logo, não é possível rejeitar a hipótese nula de que a média da série W_t é igual em diferentes meses do ano. A Figura 8 reforça a decisão tomada na ANOVA, ou seja, não há sazonalidade determinística.

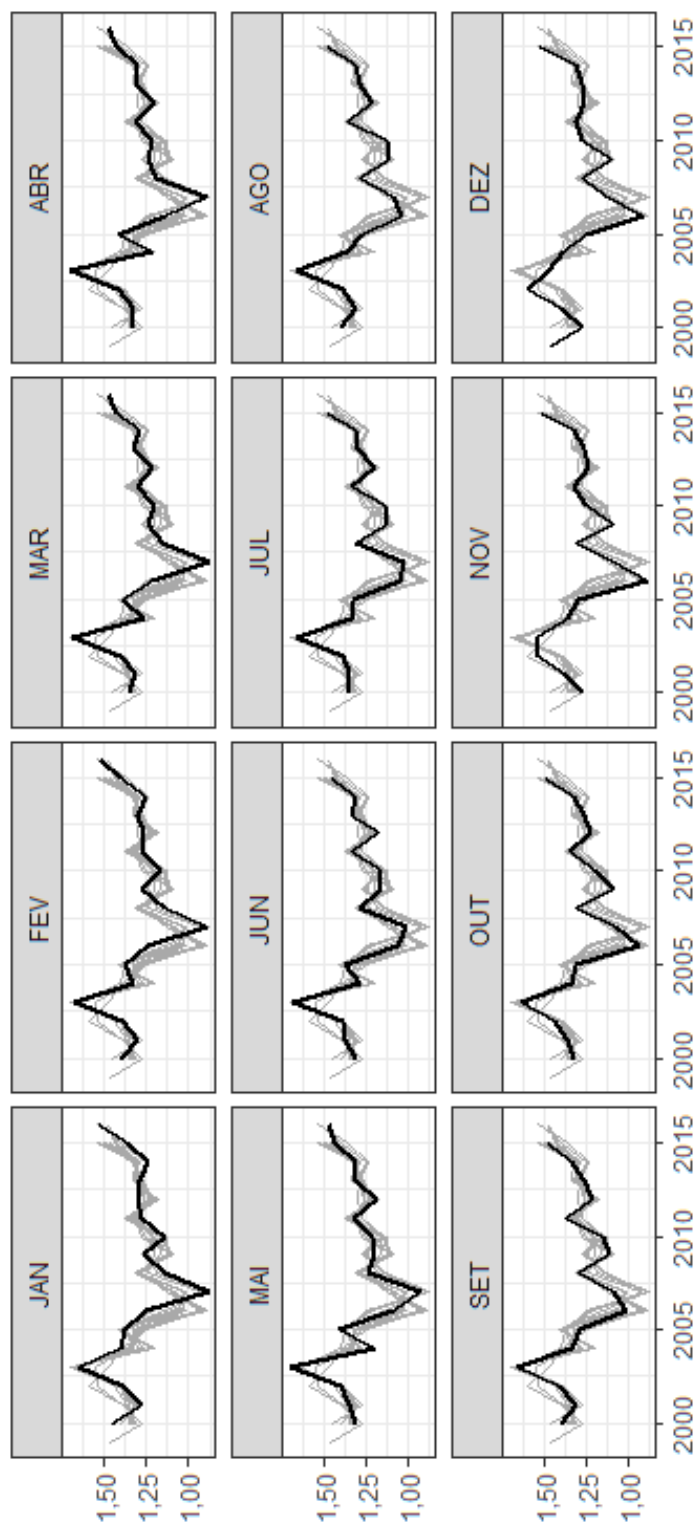


Figura 8: Transformação Box-Cox ($\lambda = -0.4$) por mês.

A linha mais escura no painel de cada mês da Figura 8 representa o mês corrente e as linhas sombreadas representam a série nos demais meses, servindo de referência para comparação entre eles.

Até então foi possível confirmar a presença da componente tendência e ausência de sazonalidade determinística, o passo seguinte do método iterativo descrito em 3.2.5 é a análise da FAC e FACP com objetivo de selecionar modelos SARIMA.

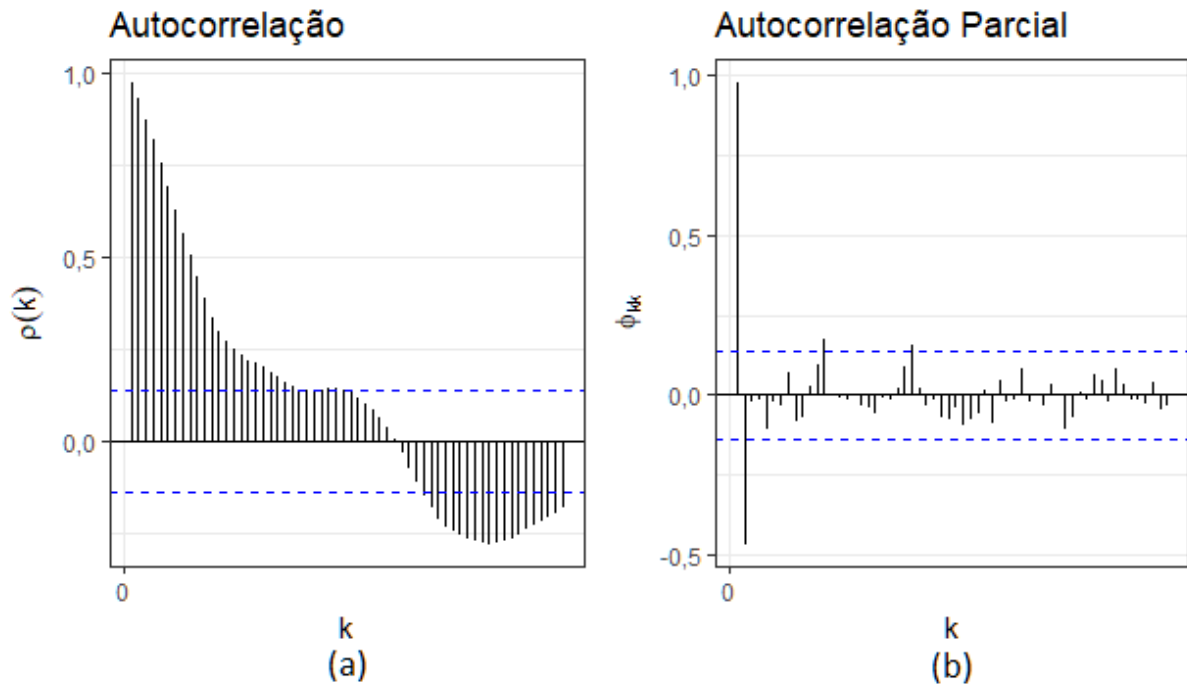


Figura 9: FAC e FACP até a defasagem 60.

Na FAC da Figura 9 (a), a presença de picos significativos até a defasagem 60 indica a necessidade de pelo menos uma diferenciação. O p -valor obtido no teste Dickey-Fuller (ADF) antes da diferença foi de 0,3702, logo, não foi possível rejeitar a hipótese nula ao nível de 5% fixado, ou seja, a série não é estacionária. Então, foi tomada uma diferença de modo que R_t seja uma série temporal estacionária, foi obtido um p -valor de 0,01 no teste ADF.

A distribuição de $R_t = (1 - B)W_t$ pode ser considerada aproximadamente normal (Figura 10), uma vez que o coeficiente de assimetria foi igual a $A = -0,1028$ e o p -valor obtido no teste de Shapiro-Wilk foi de p -valor = 0,0097, o gráfico com a diferença de primeira ordem encontra-se no Anexo B.




Figura 10: Histograma do IPCA após a primeira diferenciação.

O objetivo agora é encontrar um modelo apropriado SARIMA baseado na FAC e FACP da série diferenciada mostradas na Figura 11. Considere defasagens sazonais quando $k = 12h, h \in \mathbb{Z}$.




Figura 11: FAC e FACP da série diferenciada.

O pico significativo na defasagem 1 da FACP sugere um componente não-sazonal

AR (1). Há picos nas defasagens 12 e 24, tanto na FAC, como na FACP, mas nada de defasagens sazonais significativas após o lag 24. Isso pode sugerir um modelo AR (1) sazonal. Nas defasagens não-sazonais da FAC, existem dois picos significativos sugerindo um possível termo MA (2), esse padrão na FAC é indicativo de um modelo que não é simplesmente autoregressivo.

Consequentemente, julgando as defasagens 1 e 2 da parte MA por um decaimento exponencial na FAC, esta análise inicial sugere que um possível modelo para os dados é o SARIMA (1, 0, 0)(2, 0, 2)₁₂. Nesse caso, ao fazer suposições, a identificação de um modelo com diversas variáveis torna-se abstrata e pouco convincente. Logo, foi dado início à busca pelo melhor modelo através critério AIC, considerando 256 variações de modelos SARIMA.

As variações foram testadas de acordo com o princípio da parcimônia, no qual os modelos de ordem p, d, P e Q maiores que 4 não foram considerados. Os únicos valores fixados para quantidade de parâmetros foram os operadores da diferença $d=1$ e $D=0$ (operador sazonal), dado que com apenas uma diferença a série é estacionária. Logo, foram estimados 256 modelos e selecionados os 10 melhores valores de AIC e de Raiz do Erro Quadrático Médio (RMSE), mostrados na Tabela 8 e na Tabela 9 a seguir. A tabela completa com todos os modelos encontra-se no Anexo B.

Tabela 8: Modelos ordenados pelo AIC.

	AIC	BIC	RMSE
SARIMA(1 1 2)(2 0 3)	-902,367	-872,819	0,023101
SARIMA(2 1 3)(1 0 2)	-902,367	-872,819	0,023101
SARIMA(1 1 3)(2 0 2)	-902,367	-872,819	0,023101
SARIMA(3 1 2)(2 0 0)	-900,931	-874,665	0,02316
SARIMA(2 1 0)(3 0 2)	-900,931	-874,665	0,02316
SARIMA(2 1 2)(3 0 0)	-900,931	-874,665	0,02316
SARIMA(3 1 0)(2 0 2)	-900,931	-874,665	0,023159
SARIMA(0 1 2)(3 0 0)	-900,507	-880,808	0,023658
SARIMA(0 1 0)(3 0 2)	-900,507	-880,808	0,023658
SARIMA(3 1 0)(0 0 2)	-900,507	-880,808	0,023658

Tabela 9: Modelos ordenados pelo BIC.

	AIC	BIC	RMSE
SARIMA(0 1 0)(1 0 0)	-892,349	-885,783	0,024786
SARIMA(1 1 0)(0 0 0)	-892,349	-885,783	0,024786
SARIMA(0 1 0)(0 0 2)	-893,155	-883,305	0,024607
SARIMA(0 1 2)(0 0 0)	-893,155	-883,305	0,024607
SARIMA(0 1 0)(2 0 0)	-891,607	-881,757	0,024706
SARIMA(2 1 0)(0 0 0)	-891,607	-881,757	0,024706
SARIMA(1 1 0)(1 0 0)	-891,524	-881,674	0,024711
SARIMA(0 1 0)(1 0 1)	-891,341	-881,491	0,024723
SARIMA(0 1 1)(1 0 0)	-891,341	-881,491	0,024723
SARIMA(1 1 0)(0 0 1)	-891,341	-881,491	0,024723

Os melhores modelos são $SARIMA(1, 1, 2)(2, 0, 3)_{12}$; $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ e $SARIMA(1, 1, 3)(2, 0, 2)_{12}$, ou seja, os que apresentaram o menor valor de AIC e de RMSE. A escolha desses modelos é razoável pois levam em conta pelo menos uma componente sazonal de ordem 2 e uma componente sazonal autoregressiva de ordem maior que 1 identificadas na FAC e FACP da Figura 11.

Note que, a diferença entre AIC e BIC está no fato de que o BIC leva em conta o tamanho de amostra, penalizando o número de parâmetros pelo log do tamanho de amostra 3.2.7.1.

Tabela 10: Coeficientes dos modelos SARIMA.

Modelo	ϕ_1	ϕ_2	θ_1	θ_2	θ_3	Φ_1	Φ_2	Θ_1	Θ_2	Θ_3
SARIMA(1 1 2)(2 0 3)	0,96		0,41	0,44		-1,37	-0,69	0,69	-0,73	-0,96
SARIMA(2 1 3)(1 0 2)	-1,37	-0,69	0,69	-0,73	-0,96	0,96		0,41	0,44	
SARIMA(1 1 3)(2 0 2)	0,96		0,69	-0,73	-0,96	-1,37	-0,69	0,41	0,44	

A Tabela 11 apresenta medidas de qualidade de estimação, os dados estimados pelos modelos descritos na Tabela 10 foram comparados com os valores observados usando o RMSE, MAE, MPE e MAPE. Essas medidas de erro de estimação foram computadas com auxílio do software R e a semelhança entre elas é notável. A seguir será feita a análise dos resíduos de cada modelo e a previsão.

Tabela 11: Medidas de qualidade de ajuste.

	RMSE	MAE	MPE	MAPE
SARIMA(1 1 2)(2 0 3)	0,02310069	0,01777585	-0,08301625	1,414688
SARIMA(2 1 3)(1 0 2)	0,02310068	0,01777593	-0,08302006	1,414694
SARIMA(1 1 3)(2 0 2)	0,02310071	0,01777591	-0,08291759	1,414689

A Figura 12 apresenta os resíduos padronizados do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$, o teste de Ljung-Box e a Figura 13 apresenta a FAC e FACP dos resíduos padronizados.

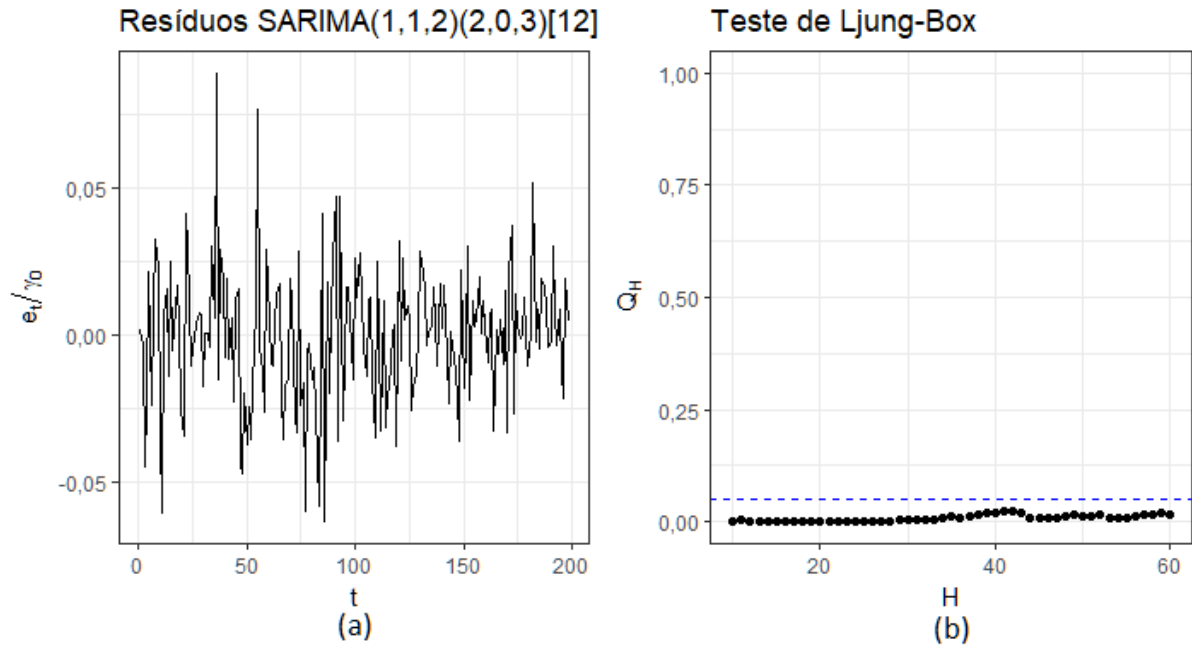


Figura 12: Resíduos do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$.

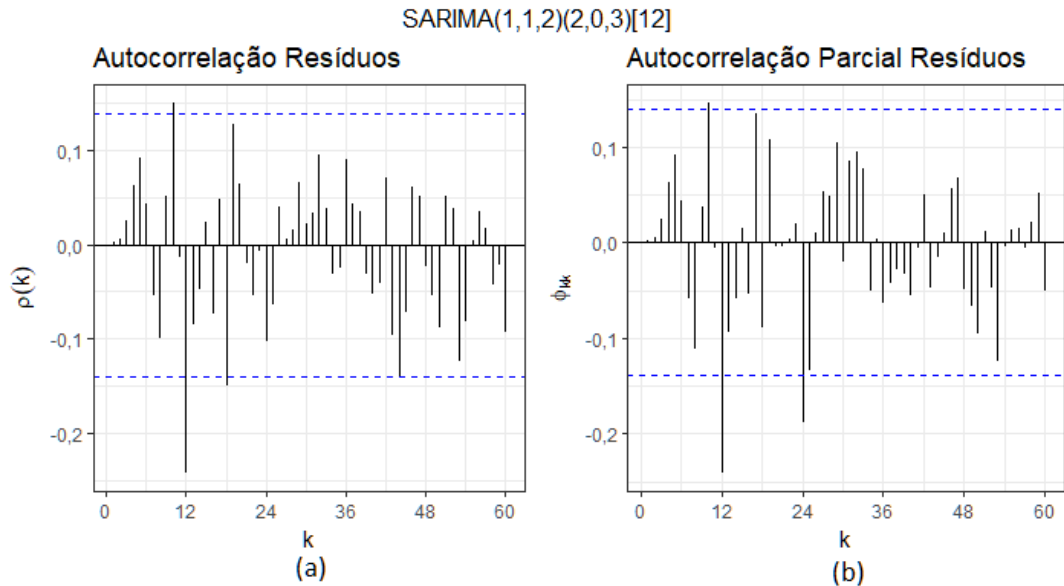


Figura 13: FAC e FACP dos resíduos do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$.

Há picos significativos tanto no FAC como na FACP dos resíduos padronizados do modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$, o modelo falha no teste de Ljung-Box, ou seja, os resíduos são correlacionados. Os modelos ainda podem ser usados para previsão, mas

os intervalos de previsão podem não ser precisos devido aos resíduos correlacionados. Segundo Morettin e Toloi(2006), tomando a diferença ($d=1$) elimina-se tendência, no entanto, há casos em que introduz-se correlação nos resíduos, fato que pode explicar o fracasso na verificação da suposição de resíduos não correlacionados.

Os intervalos de confiança para a previsão são de 80% e 95%, os pontos pretos representam os valores observados no período de previsão, e os azuis representam os valores previstos.




Figura 14: Previsão usando o modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$.

A Figura 15 apresenta a análise dos resíduos padronizados para o modelo selecionado SARIMA $(2, 1, 3)(1, 0, 2)_{12}$ e a Figura 16 a FAC e FACP dos resíduos padronizados.

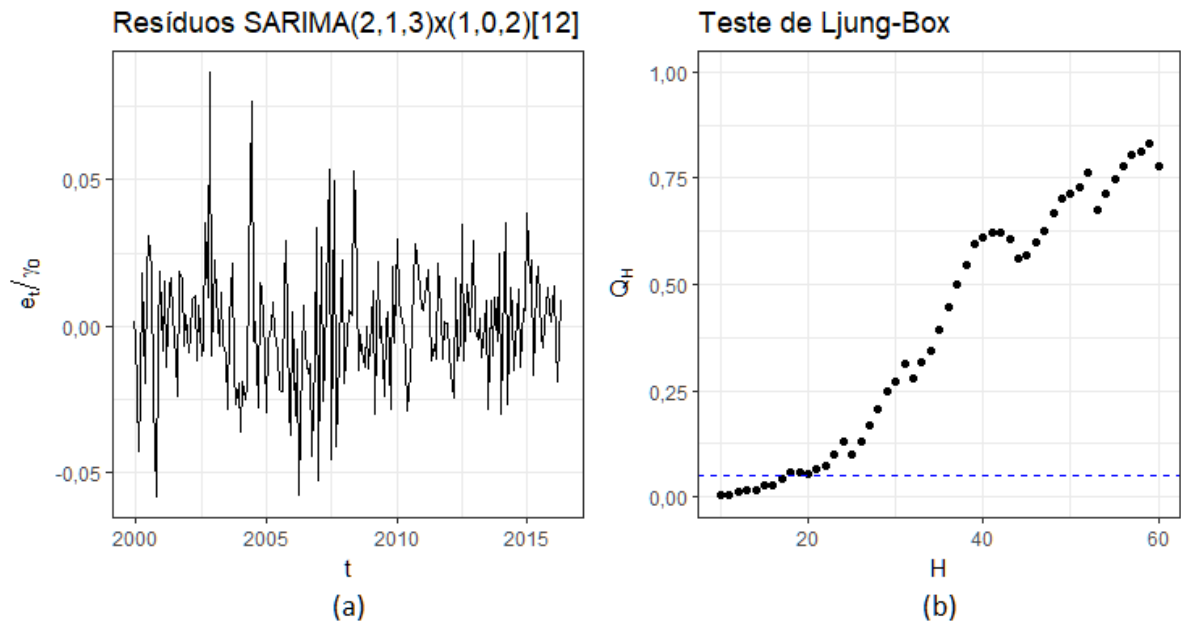


Figura 15: Resíduos do modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$.

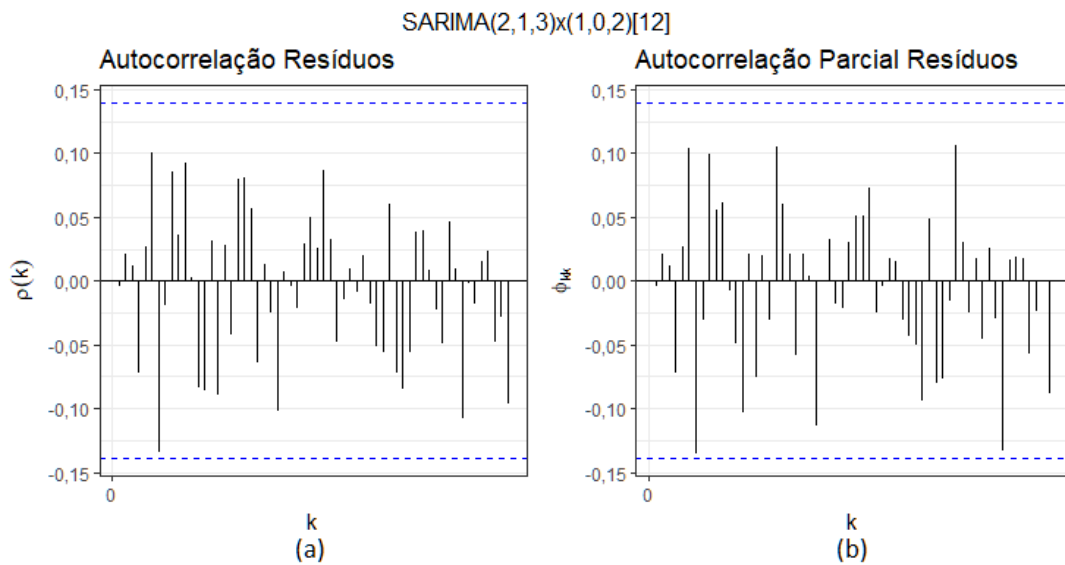


Figura 16: FAC e FACP dos resíduos do modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$.

Já na FAC e FACP dos resíduos padronizados do modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ (Figura 16) não há picos significativos e o modelo falha no teste de Ljung-Box. Ao comparar o modelo $SARIMA(1, 1, 2)(2, 0, 3)_{12}$ com o modelo2, percebe-se que o modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ apresentou, na FAC e FACP, resíduos dentro do intervalo de confiança estimado para um ruído branco gaussiano (linha pontilhada em azul), enquanto

o modelo SARIMA $(1, 1, 2)(2, 0, 3)_{12}$ apresentou picos significativos em algumas defasagens sazonais.

Além disso, o modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$ apresentou melhor performance quanto ao teste de Ljung-Box. Observa-se que os resíduos são correlacionados até a defasagem 16. O modelo foi usado para previsão do IPCA dos meses de junho de 2016 a novembro de 2017.

Os intervalos de confiança para a previsão são de 80% e 95% e os pontos representam os valores observados de junho de 2016 em diante.

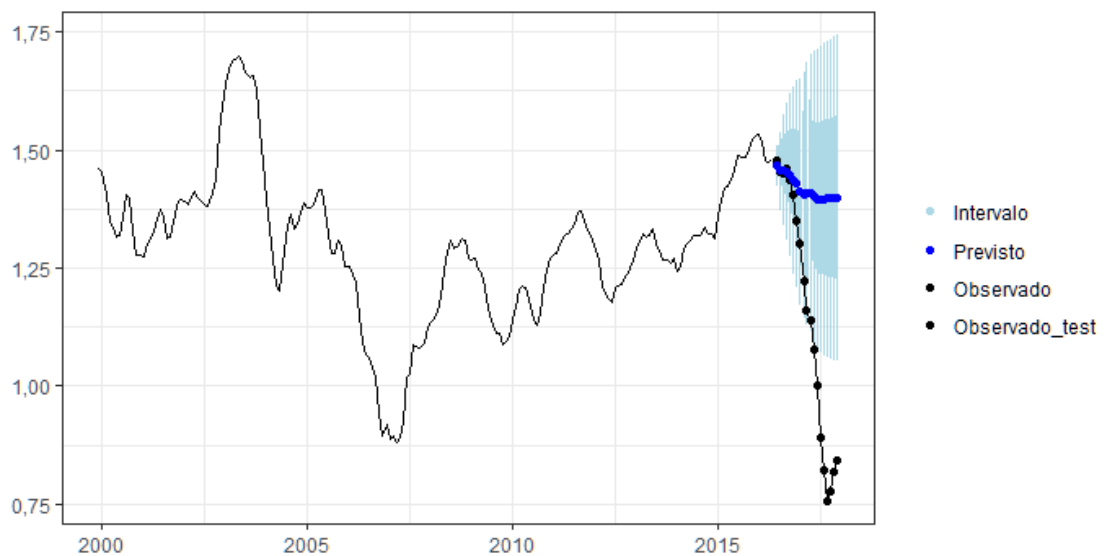


Figura 17: Previsão usando o modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$.

A Figura 18 apresenta a análise dos resíduos padronizados para o modelo selecionado $SARIMA(1, 1, 3)(2, 0, 2)_{12}$ e a Figura 19 a FAC e FACP dos resíduos padronizados.

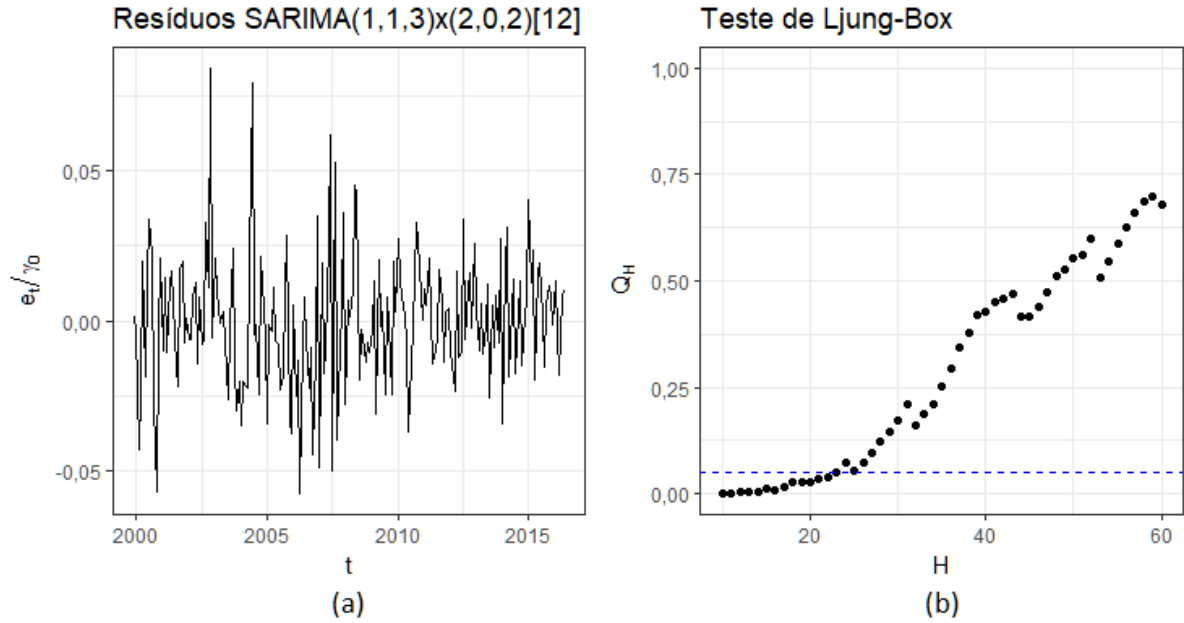


Figura 18: Resíduos do modelo $SARIMA(1, 1, 3)(2, 0, 2)_{12}$.

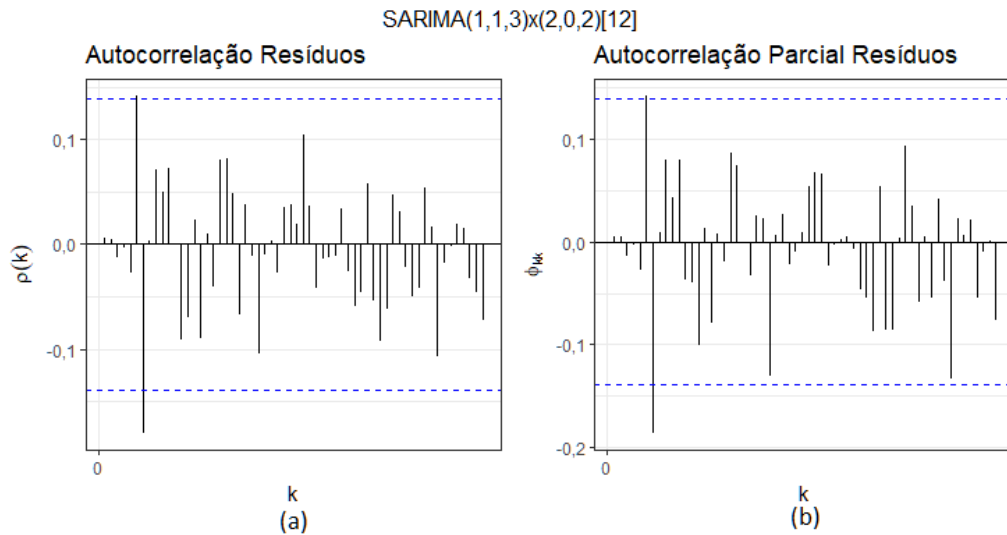


Figura 19: FAC e FACP do modelo $SARIMA(1, 1, 3)(2, 0, 2)_{12}$.

A FAC e FACP dos resíduos padronizados do terceiro, e último modelo, apresentam picos significativos nas defasagem 5, 6 e 7, o modelo falha no teste de Ljung-Box até a defasagem 20. Os intervalos de confiança para a previsão são de 80% e 95%. Tendo em vista os picos significativos na FAC e FACP do modelo $SARIMA(1, 1, 3)(2, 0, 2)_{12}$, o modelo

$SARIMA(2, 1, 3)(1, 0, 2)_{12}$ foi considerado melhor do que o modelo $SARIMA(1, 1, 3)(2, 0, 2)_{12}$.




Figura 20: Previsão usando o modelo $SARIMA(1, 1, 3)(2, 0, 2)_{12}$.

Na Tabela 12 foi feito um comparativo das medidas de qualidade de previsão do IPCA efetivo para os 3 modelos no período de junho de 2016 a novembro de 2017 (19 meses).

Tabela 12: Medidas de qualidade de previsão.

	RMSE	MAPE	MAE
$SARIMA(1, 1, 2)(2, 0, 3)_{12}$	3,6768	91,0930	3,0569
$SARIMA(2, 1, 3)(1, 0, 2)_{12}$	3,3782	83,3446	2,7174
$SARIMA(1, 1, 3)(2, 0, 2)_{12}$	3,6155	89,3648	2,9594

Novamente, o modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ apresentou melhor desempenho, sendo assim, o modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$ foi o modelo escolhido para representar a série do IPCA. Foram feitas as previsões com relação ao IPCA Efetivo e utilizada a transformação inversa (3.9) para tornar os resultados comparáveis. A Figura 21, apresenta os valores das previsões do modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$.



Figura 21: Previsão, estimação, limites do intervalo de confiança de 95% e IPCA observado.

As linhas vermelha e verde representam o IPCA e o IPCA estimado pelo modelo $SARIMA(2, 1, 3)(1, 0, 2)_{12}$, respectivamente. Os pontos azuis representam as previsões e cada barra vertical representa o intervalo de confiança para cada previsão. Foi observado que, de acordo com o sistema de metas (Tabela 2), a meta para o IPCA no ano de 2016 era de 4,5% com tolerância de 2,5% a 6,5%.

Porém, o valor previsto para dezembro de 2016 foi de aproximadamente 8,65%, ou seja, fora do intervalo de tolerância estipulado para o ano e com erro absoluto de 2,36 quanto ao IPCA observado nesse mês (6,29%). Além disso, nota-se que a capacidade preditiva do modelo é perdida com apenas 6 defasagens, os valores do IPCA estão distantes do intervalo de confiança de 95% para a previsão, revelando-se previsões insatisfatórias. Os outros modelos apresentaram erros maiores se comparados ao modelo selecionado, as tabelas completas com os erros das previsões, com os limites de confiança e com as previsões feitas estão no Anexo B.

5 Conclusão

O IPCA é um dos índices mais importantes da economia, o índice mede a variação de preços do mercado para o consumidor final e reflete o custo de vida de famílias brasileiras. O desenvolvimento do presente estudo possibilitou uma análise de como funcionam os modelos clássicos de previsão para séries temporais, os modelos do tipo SARIMA demonstraram não ter capacidade preditiva a longo prazo.

Os modelos selecionados pelos menores erros de estimação, $\text{SARIMA}(1, 1, 2)(2, 0, 3)_{12}$; $\text{SARIMA}(2, 1, 3)(1, 0, 2)_{12}$ e $\text{SARIMA}(1, 1, 3)(2, 0, 2)_{12}$, forneceram previsões de junho de 2016 a novembro de 2017 e foram comparados com os valores observados ao longo do período de previsão. Além disso, a apuração dos resultados permitiu compreender melhor a natureza do indicador, percebeu-se a presença da componente não observável tendência, e foi descartada a hipótese de sazonalidade determinística na composição do modelo. Os resultados de estimação foram satisfatório, enquanto os resultados de previsão não corresponderam à expectativa. Portanto, a abordagem proposta por esse estudo pode ser útil apenas para previsões de curto prazo.

Por outro lado, para obter previsões mais consistentes, de médio e longo prazo seria necessária outra abordagem. A taxa básica de juros é um instrumento do Banco Central para influenciar a inflação da economia, a SELIC serve, basicamente, de referência para empréstimos do BCB às instituições financeiras. Tendo em vista a relação intrínseca entre esses dois indicadores, suspeita-se que os cortes sistemáticos na taxa SELIC influenciaram a drástica queda da inflação efetiva observada no ano de 2017, nesse sentido, formulações dinâmicas poderiam ser adotadas para avaliar essa relação, tais como Modelos Dinâmicos Bayesianos e Modelos Estruturais.

Referências

- [1] Hirotogu Akaike. Information theory and an extension of the maximum likelihood principle. In *Selected papers of hirotugu akaike*, pages 199–213. Springer, 1998.
- [2] R Artusi, P Verderio, and E Marubini. Bravais-pearson and spearman correlation coefficients: meaning, test of hypothesis and confidence interval. *Int J Biol Markers*, 17(148-151. PMID):12113584, 2002.
- [3] John M Bates and Clive WJ Granger. The combination of forecasts. *Or*, pages 451–468, 1969.
- [4] BCB. Resolução n. ° 4.499, de 30 de junho de 2016. *Diário Oficial da União, Seção 1*, page 55, 2016.
- [5] BCB. Resolução n. ° 4.582, de 29 de junho de 2017. *Diário Oficial da União, Seção 1*, page 37, 2017.
- [6] George EP Box, Gwilym M Jenkins, Gregory C Reinsel, and Greta M Ljung. *Time series analysis: forecasting and control*. John Wiley & Sons, 1970.
- [7] Brasil. Decreto n. ° 3.008, de 21 de junho de 1999. *Diário Oficial da União, Seção 1*, page 4, 1999.
- [8] Peter J Brockwell and Richard A Davis. *Time series: theory and methods*. Springer Science & Business Media, 2013.
- [9] DE CONJUNTURA CARTA. Rio de janeiro: Ipea, n. 36, jul. 2017.
- [10] DE CONJUNTURA CARTA. Rio de janeiro: Ipea, n. 37, out. 2017.
- [11] Ciclo de Debates, Anos de Plano Real, and Arilma da Silva Peixoto. O plano real. 2004.
- [12] Ana Maria Lima de Farias and Luiz da Costa Laurencel. Números índices, 2015.
- [13] David A Dickey and Wayne A Fuller. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American statistical association*, 74(366a):427–431, 1979.
- [14] Paulo C EMILIANO, Elayne P VEIGA, Mário JF VIVANCO, and Fortunato S MENEZES. Critérios de informação de akaike versus bayesiano: análise comparativa. *19º Simpósio Nacional de Probabilidade e Estatística*, 2010.
- [15] Robert F Engle. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. *Econometrica: Journal of the Econometric Society*, pages 987–1007, 1982.

- [16] FGV. Disponível em: <http://www.portal.fgv.br>. Acesso em, 12, 2017.
- [17] FIPE. Disponível em: <http://www.fipe.org.br>. Acesso em, 12, 2017.
- [18] Jeff Harrison and Mike West. *Bayesian forecasting & dynamic models*, volume 1030. Springer New York City, 1999.
- [19] IBGE. Disponível em: <http://www.ibge.gov.br>. Acesso em, 12, 2017.
- [20] IBGE. *Sistema Nacional de Preços ao Consumidor: Métodos de Cálculo.*, volume 14. Série Relatórios Metodológicos, Rio e Janeiro: 2006.
- [21] Phillip Inman. Brazil's economy overtakes uk to become world's sixth largest. guardian newspaper, 2012.
- [22] Carlos M Jarque and Anil K Bera. Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics letters*, 6(3):255–259, 1980.
- [23] Greta M Ljung and George EP Box. On a measure of lack of fit in time series models. *Biometrika*, 65(2):297–303, 1978.
- [24] Francisco Lafaiete Lopes et al. Inflação inercial, hiperinflação e desinflação: notas e conjecturas. 1984.
- [25] Gilmar Mendes Lourenço and Mario Romero. Indicadores econômicos. *FAE BUSINESS SCHOOL. Economia empresarial. Curitiba: Associação Franciscana de Ensino Senhor Bom Jesus*, pages 27–41, 2002.
- [26] Carlos Antonio Luque and Marco Antonio Sandoval de VASCONCELLOS. Considerações sobre o problema da inflação. *Manual de economia*, 5:336–51, 2002.
- [27] Eduardo Barrozo Marques. *Combinação de previsões de índices de preços*. PhD thesis, 2005.
- [28] Francisco Martínez-Álvarez, Alicia Troncoso, Gualberto Asencio-Cortés, and José C Riquelme. A survey on data mining techniques applied to electricity-related time series forecasting. *Energies*, 8(11):13162–13193, 2015.
- [29] Aidan Meyler, Geoff Kenny, and Terry Quinn. Forecasting irish inflation using arima models. 1998.
- [30] Pedro A Morettin and Clélia Toloi. *Análise de séries temporais*. Blucher, 2006.
- [31] Emi Nakamura. Inflation forecasting using a neural network. *Economics Letters*, 86(3):373–378, 2005.
- [32] OECD. *Statistics, Knowledge and Policy: Key Indocators to Inform Decision Making*, volume 14. OECD Publishing, 1996.
- [33] Sandra C Oliveira and Marinho G Andrade. Abordagem bayesiana para modelos estocásticos com heterocedasticidade para os retornos ibovespa. *19o Simpósio Nacional de Probabilidade e Estatística*, 2010.

- [34] Tommaso Proietti and Helmut Lütkepohl. Does the box–cox transformation help in forecasting macroeconomic time series? *International Journal of Forecasting*, 29(1):88–99, 2013.
- [35] Salomão Quadros, Maria Cecilia Prates Rodrigues, Moacyr Antonio Fioravante, and Paulo Cesar Stilpen. Índices de preços: História, fórmulas e divergências. *Revista Conjuntura Econômica*, 45(3):36–37, 1991.
- [36] Nelson Senra et al. *História das estatísticas brasileiras*, volume 4. Ministério do Planejamento, Orçamento e Gestão, Instituto Brasileiro de Geografia e Estatística–IBGE, Centro de Documentação e Disseminação de Informações, 2009.
- [37] Felipe Cauê Serigati and Roberta Possamai. Inflação de demanda. *AgroANALYSIS*, 34(05):13–15.
- [38] IBGE Sidra. Disponível em: www.sidra.ibge.gov.br, 2017.
- [39] Reinaldo C Souza and Maria E CAMARGO. Análise e previsão de séries temporais: os modelos arima. *Ijuí: Sedigraf*, 1996.
- [40] Paulo Trevisani and Rogerio Jelmayer. Brazil’s dilma roussef defends austerity measures in tv address. *The Wall Street Journal*, 2015.
- [41] C VALLE. *Métodos de Simulação Estocástica em modelos Dinâmicos Não) Lineares: Uma aplicação em modelos de Volatilidade*. PhD thesis, Tese de Doutorado. IM, UFRJ, 2005.

ANEXO A – Programação estatística

O presente estudo foi realizado com auxílio de bibliotecas do software R, de modo que, as bibliotecas *xts* e *lubridate* foram utilizadas na manipulação de objetos do tipo data; *ggplot2*, *ggfortify*, *gridExtra*, *scales*, *plotly* e *dygraphs* na produção de gráficos; *itsmr*, *forecast*, *fBasics*, *fUnitRoot*, *timeSeries*, *tseries* usadas para testes estatísticos, estimação e previsão. Os pacotes citados estão disponíveis nos sites <https://cran.r-project.org> e <https://r-forge.r-project.org/>.

As rotinas descritas abaixo foram armazenadas em arquivos .r separadamente e referenciadas no script principal pelo comando *source*.

```
# Autocorrelacao e autocorrelacao parcial
fac_facp=function(x, titulo, lag, top)
{
  fac = acf(x, plot = F, lag.max = lag)
  facp = pacf(x, plot = F, lag.max = lag)
  h1 = autoplot(fac)+
    xlab('k')+ylab(expression(rho(k))) + ggtitle(paste("Autocorrelação",titulo))
  h2 = autoplot(facp)+
    xlab('k')+ylab(expression(phi[kk])) + ggtitle(paste("Autocorrelação Parcial",
    titulo))
  grid.arrange(h1, h2, ncol = 2, top=top) #facv ampona necessidade de
  diferenciação
}

# Grafico Ljung Box
ljungbox=function(ajuste, ordem)
{
  res = ajuste$residuals / sqrt(ajuste$sigma2) #residuo padronizado
```



```

pval = numeric(20-ordem)
for (i in (ordem+1):20)
{
  estat = Box.test(res, i,
                    type = "Ljung-Box")$statistic
  pval[i-ordem] = pchisq(estat, i - ordem,
                        lower.tail = FALSE)
}
ljung_box =
  ggplot(data.frame(x=(ordem+1):20,y= pval),
        aes(x,y)) +
  geom_point()+
  xlab('H')+ylab(expression(Q[H])) +
  ggtitle('Teste de Ljung-Box ') +
  ylim(c(0,1))+
  geom_hline(yintercept = 0.05, colour = 'blue',
            lty=2)
ljung_box
}

# Avaliação de Normalidade
norm_test=function(ajuste, titulo )
{
  res = ajuste$residuals / sqrt(ajuste$sigma2) #residuo padronizado
  #QQnorm
  dados = data.frame(res = as.numeric(res))
  qqplot=ggplot(dados, aes(sample = res)) + stat_qq() +
  geom_abline(intercept = mean(res),slope = sd(res)) +
  xlab('Quantis teóricos')+
  ylab('Quantis amostrais')+
  ggtitle(paste('QQnorm',titulo))

  #Teste de normalidade de Jarque-Bera
  # print(jarqueberaTest(res))
  autoplot(qqplot)
}

```

```
}
```

```
#Previsão
```

```
previsao=function(ajuste, n, alpha)
```

```
{
```

```
  previsao = forecast::forecast(ajuste, h = n, level = alpha)
```

```
  print(previsao$mean)
```

```
  autoplot(previsao)+ggtitle('Previsão')+  
    xlab('t')+ylab(expression(x[t])) +
```

```
    geom_line(data=ipca) +
```

```
    scale_color_manual("Dataset",
```

```
                        values = c("p1" = "darkgreen", "p2" = "red"))
```

```
}
```

ANEXO B – Tabelas e Outros Resultados

Neste anexo serão apresentados os resultados gerados que não foram incluídos no decorrer do texto.

Pela Figura 22, percebe-se que após uma diferenciação a série se torna estacionário com média aproximadamente zero.




Figura 22: Transformação Box-Cox com (d=1)

Tabela 13: Valores Discrepantes do IPCA

Ano e mês	IPCA	Ano e mês	IPCA	Ano e mês	IPCA	Ano e mês	IPCA
1994 JAN	269,84	1995 FEV	426,83	1996 MAR	20,55	2003 AGO	15,07
1994 FEV	3035,71	1995 MAR	274,78	1996 ABR	19,17	2003 SET	15,14
1994 MAR	3417,39	1995 ABR	169,05	1996 MAI	17,49	2003 OUT	13,98
1994 ABR	3828,49	1995 MAI	91,79	1996 JUN	16,26		
1994 MAI	4331,19	1995 JUN	33,03	1996 JUL	14,84		
1994 JUN	4922,60	1995 JUL	27,45	1996 AGO	14,21		
1994 JUL	4005,08	1995 AGO	26,36	2003 JAN	14,47		
1994 AGO	3044,89	1995 SET	25,69	2003 FEV	15,85		
1994 SET	2253,15	1995 OUT	24,21	2003 MAR	16,57		
1994 OUT	1703,17	1995 NOV	22,59	2003 ABR	16,77		
1994 NOV	1267,54	1995 DEZ	22,41	2003 MAI	17,24		
1994 DEZ	916,46	1996 JAN	21,97	2003 JUN	16,57		
1995 JAN	631,54	1996 FEV	21,99	2003 JUL	15,43		

Tabela 14: IPCA Transformado por mês.

Ano	JAN	FEV	MAR	ABR	MAI	JUN	JUL	AGO	SET	OUT	NOV	DEZ
2000	1,670054	1,492328	1,56521	1,692276	1,611349	1,135335	1,238802	1,380579	1,243343	1,482036	1,481089	1,48298
2001	1,664321	1,530585	1,601158	1,584675	1,609907	1,109032	1,253791	1,340819	1,274093	1,454815	1,482036	1,50512
2002	1,595976	1,556383	1,637926	1,499679	1,549859	1,017433	1,261131	1,288134	1,340819	1,416378	1,50059	1,490473
2003	1,520211	1,531439	1,780843	1,42068	1,488611	0,960629	1,278345	1,244848	1,392041	1,345806	1,459788	1,487677
2004	1,50692	1,47345	1,852915	1,348281	1,434408	0,989715	1,320379	1,223384	1,422816	1,328138	1,441646	1,47345
2005	1,47919	1,478238	1,926138	1,334517	1,436487	0,953129	1,386343	1,220247	1,431273	1,313823	1,417457	1,539061
2006	1,48298	1,543243	1,971077	1,438557	1,468614	0,960629	1,438557	1,192824	1,433365	1,304504	1,415297	1,583912
2007	1,532292	1,576986	1,99261	1,5105	1,454815	0,945534	1,469585	1,201034	1,462747	1,340819	1,407664	1,615649
2008	1,595976	1,581615	1,998383	1,542409	1,398796	0,95564	1,449791	1,215507	1,48298	1,345806	1,422816	1,618494
2009	1,589229	1,577761	2,011615	1,50059	1,399913	0,999101	1,457805	1,258207	1,486741	1,350744	1,387488	1,639283
2010	1,496018	1,569168	1,99261	1,514939	1,378256	1,107105	1,47345	1,292274	1,5015	1,37122	1,397677	1,666878
2011	1,431273	1,587716	1,957939	1,547389	1,355636	1,116673	1,471521	1,337047	1,515821	1,380579	1,447768	1,707662
2012	1,429172	1,604823	1,946313	1,57621	1,264039	1,194476	1,421749	1,348281	1,546562	1,415297	1,460776	1,705914
2013	1,423881	1,589229	1,948601	1,561218	1,202661	1,189505	1,415297	1,343318	1,553132	1,447768	1,469585	1,703572
2014	1,459788	1,580846	1,908863	1,559612	1,16916	1,184489	1,421749	1,293647	1,524561	1,46373	1,483923	1,728671
2015	1,476329	1,569168	1,785242	1,571527	1,158699	1,196123	1,38977	1,259671	1,495098	1,490473	1,482036	1,758143

Tabela 15: Previsão, intervalo e erro de previsão para o SARIMA $(1, 1, 2)(2, 0, 3)_{12}$.

Ano	Mês	Limite Inferior	Previsão	L. Superior	IPCA Efetivo	Erro
2016	MAI	8,389083	9,353608	10,48082	9,32	0,033608
2016	JUN	7,587883	9,361734	11,77519	8,84	0,521734
2016	JUL	6,859307	9,214845	12,87917	8,74	0,474845
2016	AGO	6,334764	9,05272	13,7315	8,97	0,08272
2016	SET	5,990643	8,993867	14,61429	8,48	0,513867
2016	OUT	5,686026	8,828514	15,06372	7,87	0,958514
2016	NOV	5,455529	8,757339	15,70799	6,99	1,767339
2016	DEZ	5,257866	8,649662	16,11449	6,29	2,359662
2017	JAN	5,081306	8,545688	16,4867	5,35	3,195688
2017	FEV	4,941598	8,477583	16,8899	4,76	3,717583
2017	MAR	4,805421	8,374056	17,11988	4,57	3,804056
2017	ABR	4,694589	8,308432	17,43181	4,08	4,228432
2017	MAI	4,591753	8,228958	17,63733	3,6	4,628958
2017	JUN	4,49848	8,155211	17,82985	3	5,155211
2017	JUL	4,418502	8,094851	18,02542	2,71	5,384851
2017	AGO	4,341055	8,023627	18,1477	2,46	5,563627
2017	SET	4,274559	7,968419	18,29872	2,54	5,428419
2017	OUT	4,211792	7,908694	18,40027	2,7	5,208694
2017	NOV	4,154374	7,853438	18,49521	2,8	5,053438

Tabela 16: Previsão, limite do intervalo de confiança e erro absoluto de previsão para o modelo SARIMA $(2, 1, 3)(1, 0, 2)_{12}$.

Ano	Mês	Limite Inferior	Previsão	L. Superior	IPCA Efetivo	Erro
2016	MAI	8,389083	9,353608	10,48082	9,32	0,033608
2016	JUN	7,587883	9,361734	11,77519	8,84	0,521734
2016	JUL	6,859307	9,214845	12,87917	8,74	0,474845
2016	AGO	6,334764	9,05272	13,7315	8,97	0,08272
2016	SET	5,990643	8,993867	14,61429	8,48	0,513867
2016	OUT	5,686026	8,828514	15,06372	7,87	0,958514
2016	NOV	5,455529	8,757339	15,70799	6,99	1,767339
2016	DEZ	5,257866	8,649662	16,11449	6,29	2,359662
2017	JAN	5,081306	8,545688	16,4867	5,35	3,195688
2017	FEV	4,941598	8,477583	16,8899	4,76	3,717583
2017	MAR	4,805421	8,374056	17,11988	4,57	3,804056
2017	ABR	4,694589	8,308432	17,43181	4,08	4,228432
2017	MAI	4,591753	8,228958	17,63733	3,6	4,628958
2017	JUN	4,49848	8,155211	17,82985	3	5,155211
2017	JUL	4,418502	8,094851	18,02542	2,71	5,384851
2017	AGO	4,341055	8,023627	18,1477	2,46	5,563627
2017	SET	4,274559	7,968419	18,29872	2,54	5,428419
2017	OUT	4,211792	7,908694	18,40027	2,7	5,208694
2017	NOV	4,154374	7,853438	18,49521	2,8	5,053438

Tabela 17: Previsão, intervalo e erro de previsão para o modelo SARIMA(1, 1, 3)(2, 0, 2)₁₂.

Ano	Mês	Limite Inferior	Previsão	L. Superior	IPCA Efetivo	Erro
2016	MAI	8,389083	9,353608	10,48082	9,32	0,033608
2016	JUN	7,587883	9,361734	11,77519	8,84	0,521734
2016	JUL	6,859307	9,214845	12,87917	8,74	0,474845
2016	AGO	6,334764	9,05272	13,7315	8,97	0,08272
2016	SET	5,990643	8,993867	14,61429	8,48	0,513867
2016	OUT	5,686026	8,828514	15,06372	7,87	0,958514
2016	NOV	5,455529	8,757339	15,70799	6,99	1,767339
2016	DEZ	5,257866	8,649662	16,11449	6,29	2,359662
2017	JAN	5,081306	8,545688	16,4867	5,35	3,195688
2017	FEV	4,941598	8,477583	16,8899	4,76	3,717583
2017	MAR	4,805421	8,374056	17,11988	4,57	3,804056
2017	ABR	4,694589	8,308432	17,43181	4,08	4,228432
2017	MAI	4,591753	8,228958	17,63733	3,6	4,628958
2017	JUN	4,49848	8,155211	17,82985	3	5,155211
2017	JUL	4,418502	8,094851	18,02542	2,71	5,384851
2017	AGO	4,341055	8,023627	18,1477	2,46	5,563627
2017	SET	4,274559	7,968419	18,29872	2,54	5,428419
2017	OUT	4,211792	7,908694	18,40027	2,7	5,208694
2017	NOV	4,154374	7,853438	18,49521	2,8	5,053438

Tabela 18: Modelos segundo os critérios de informação AIC e BIC e RMSE

Modelo	AIC	BIC	RMSE
SARIMA(0 1 0)(0 0 0)	-813,547	-810,264	0,030459
SARIMA(0 1 0)(0 0 1)	-873,759	-867,192	0,025993
SARIMA(0 1 0)(0 0 2)	-893,155	-883,305	0,024607
SARIMA(0 1 0)(0 0 3)	-892,149	-879,016	0,024544
SARIMA(0 1 0)(1 0 0)	-892,349	-885,783	0,024786
SARIMA(0 1 0)(1 0 1)	-891,341	-881,491	0,024723
SARIMA(0 1 0)(1 0 2)	-892,18	-879,047	0,024542
SARIMA(0 1 0)(1 0 3)	-890,371	-873,955	0,02453
SARIMA(0 1 0)(2 0 0)	-891,607	-881,757	0,024706
SARIMA(0 1 0)(2 0 1)	-889,779	-876,646	0,024695
SARIMA(0 1 0)(2 0 2)	-892,26	-875,844	0,024408
SARIMA(0 1 0)(2 0 3)	-888,377	-868,678	0,02453
SARIMA(0 1 0)(3 0 0)	-890,318	-877,185	0,024661
SARIMA(0 1 0)(3 0 1)	-891,291	-874,875	0,024471
SARIMA(0 1 0)(3 0 2)	-900,507	-880,808	0,023658
SARIMA(0 1 0)(3 0 3)	-898,499	-875,517	0,023662
SARIMA(0 1 1)(0 0 0)	-873,759	-867,192	0,025993
SARIMA(0 1 1)(0 0 1)	-880,043	-870,193	0,025449
SARIMA(0 1 1)(0 0 2)	-892,149	-879,016	0,024544
SARIMA(0 1 1)(0 0 3)	-890,17	-873,754	0,024543
SARIMA(0 1 1)(1 0 0)	-891,341	-881,491	0,024723
SARIMA(0 1 1)(1 0 1)	-889,402	-876,269	0,024719
SARIMA(0 1 1)(1 0 2)	-890,371	-873,955	0,02453
SARIMA(0 1 1)(1 0 3)	-888,38	-868,68	0,02453
SARIMA(0 1 1)(2 0 0)	-889,779	-876,646	0,024695
SARIMA(0 1 1)(2 0 1)	-887,848	-871,432	0,02469
SARIMA(0 1 1)(2 0 2)	-893,574	-873,875	0,024158
SARIMA(0 1 1)(2 0 3)	-886,382	-863,4	0,02453
SARIMA(0 1 1)(3 0 0)	-891,291	-874,875	0,024471
SARIMA(0 1 1)(3 0 1)	-890,142	-870,443	0,024416
SARIMA(0 1 1)(3 0 2)	-888,136	-865,154	0,024417
SARIMA(0 1 1)(3 0 3)	-886,218	-859,953	0,024412
SARIMA(0 1 2)(0 0 0)	-893,155	-883,305	0,024607
SARIMA(0 1 2)(0 0 1)	-892,149	-879,016	0,024544
SARIMA(0 1 2)(0 0 2)	-890,175	-873,759	0,024542
SARIMA(0 1 2)(0 0 3)	-891,129	-871,43	0,024321
SARIMA(0 1 2)(1 0 0)	-892,18	-879,047	0,024542
SARIMA(0 1 2)(1 0 1)	-890,371	-873,955	0,02453
SARIMA(0 1 2)(1 0 2)	-888,254	-868,555	0,024537
SARIMA(0 1 2)(1 0 3)	-886,431	-863,449	0,024527
SARIMA(0 1 2)(2 0 0)	-892,26	-875,844	0,024408
SARIMA(0 1 2)(2 0 1)	-893,574	-873,875	0,024158
SARIMA(0 1 2)(2 0 2)	-886,221	-863,239	0,024539
SARIMA(0 1 2)(2 0 3)	-884,506	-858,24	0,024522
SARIMA(0 1 2)(3 0 0)	-900,507	-880,808	0,023658
SARIMA(0 1 2)(3 0 1)	-888,136	-865,154	0,024417
SARIMA(0 1 2)(3 0 2)	-886,142	-859,876	0,024417

SARIMA(0 1 2)(3 0 3)	-884,213	-854,664	0,024412
SARIMA(0 1 3)(0 0 0)	-892,149	-879,016	0,024544
SARIMA(0 1 3)(0 0 1)	-890,17	-873,754	0,024543
SARIMA(0 1 3)(0 0 2)	-891,129	-871,43	0,024321
SARIMA(0 1 3)(0 0 3)	-886,242	-863,26	0,024538
SARIMA(0 1 3)(1 0 0)	-890,371	-873,955	0,02453
SARIMA(0 1 3)(1 0 1)	-888,38	-868,68	0,02453
SARIMA(0 1 3)(1 0 2)	-886,431	-863,449	0,024527
SARIMA(0 1 3)(1 0 3)	-884,633	-858,368	0,024514
SARIMA(0 1 3)(2 0 0)	-888,377	-868,678	0,02453
SARIMA(0 1 3)(2 0 1)	-886,382	-863,4	0,02453
SARIMA(0 1 3)(2 0 2)	-884,506	-858,24	0,024522
SARIMA(0 1 3)(2 0 3)	-882,634	-853,085	0,024514
SARIMA(0 1 3)(3 0 0)	-898,499	-875,517	0,023662
SARIMA(0 1 3)(3 0 1)	-886,218	-859,953	0,024412
SARIMA(0 1 3)(3 0 2)	-884,213	-854,664	0,024412
SARIMA(0 1 3)(3 0 3)	-882,192	-849,36	0,024413
SARIMA(1 1 0)(0 0 0)	-892,349	-885,783	0,024786
SARIMA(1 1 0)(0 0 1)	-891,341	-881,491	0,024723
SARIMA(1 1 0)(0 0 2)	-892,18	-879,047	0,024542
SARIMA(1 1 0)(0 0 3)	-890,371	-873,955	0,02453
SARIMA(1 1 0)(1 0 0)	-891,524	-881,674	0,024711
SARIMA(1 1 0)(1 0 1)	-889,72	-876,587	0,024699
SARIMA(1 1 0)(1 0 2)	-890,176	-873,76	0,024542
SARIMA(1 1 0)(1 0 3)	-888,18	-868,481	0,024542
SARIMA(1 1 0)(2 0 0)	-889,831	-876,699	0,024691
SARIMA(1 1 0)(2 0 1)	-890,603	-874,187	0,024515
SARIMA(1 1 0)(2 0 2)	-894,5	-874,801	0,02412
SARIMA(1 1 0)(2 0 3)	-892,919	-869,936	0,024091
SARIMA(1 1 0)(3 0 0)	-891,749	-875,333	0,024442
SARIMA(1 1 0)(3 0 1)	-890,253	-870,553	0,02441
SARIMA(1 1 0)(3 0 2)	-898,507	-875,524	0,023658
SARIMA(1 1 0)(3 0 3)	-896,516	-870,251	0,023657
SARIMA(1 1 1)(0 0 0)	-891,341	-881,491	0,024723
SARIMA(1 1 1)(0 0 1)	-889,402	-876,269	0,024719
SARIMA(1 1 1)(0 0 2)	-890,371	-873,955	0,02453
SARIMA(1 1 1)(0 0 3)	-888,38	-868,68	0,02453
SARIMA(1 1 1)(1 0 0)	-889,72	-876,587	0,024699
SARIMA(1 1 1)(1 0 1)	-887,74	-871,324	0,024697
SARIMA(1 1 1)(1 0 2)	-888,18	-868,481	0,024542
SARIMA(1 1 1)(1 0 3)	-886,373	-863,391	0,02453
SARIMA(1 1 1)(2 0 0)	-890,603	-874,187	0,024515
SARIMA(1 1 1)(2 0 1)	-890,142	-870,443	0,024417
SARIMA(1 1 1)(2 0 2)	-888,13	-865,147	0,024417
SARIMA(1 1 1)(2 0 3)	-890,979	-864,713	0,024087
SARIMA(1 1 1)(3 0 0)	-890,253	-870,553	0,02441
SARIMA(1 1 1)(3 0 1)	-888,143	-865,16	0,024416

SARIMA(1 1 1)(3 0 2)	-896,52	-870,254	0,023657
SARIMA(1 1 1)(3 0 3)	-894,685	-865,136	0,02364
SARIMA(1 1 2)(0 0 0)	-892,18	-879,047	0,024542
SARIMA(1 1 2)(0 0 1)	-890,371	-873,955	0,02453
SARIMA(1 1 2)(0 0 2)	-888,254	-868,555	0,024537
SARIMA(1 1 2)(0 0 3)	-886,431	-863,449	0,024527
SARIMA(1 1 2)(1 0 0)	-890,176	-873,76	0,024542
SARIMA(1 1 2)(1 0 1)	-888,18	-868,481	0,024542
SARIMA(1 1 2)(1 0 2)	-886,248	-863,266	0,024538
SARIMA(1 1 2)(1 0 3)	-884,381	-858,115	0,02453
SARIMA(1 1 2)(2 0 0)	-894,5	-874,801	0,02412
SARIMA(1 1 2)(2 0 1)	-888,13	-865,147	0,024417
SARIMA(1 1 2)(2 0 2)	-886,121	-859,855	0,024418
SARIMA(1 1 2)(2 0 3)	-902,367	-872,819	0,023101
SARIMA(1 1 2)(3 0 0)	-898,507	-875,524	0,023658
SARIMA(1 1 2)(3 0 1)	-897,359	-871,094	0,023599
SARIMA(1 1 2)(3 0 2)	-894,521	-864,972	0,023745
SARIMA(1 1 2)(3 0 3)	-882,219	-849,387	0,024412
SARIMA(1 1 3)(0 0 0)	-890,371	-873,955	0,02453
SARIMA(1 1 3)(0 0 1)	-888,38	-868,68	0,02453
SARIMA(1 1 3)(0 0 2)	-886,431	-863,449	0,024527
SARIMA(1 1 3)(0 0 3)	-884,633	-858,368	0,024514
SARIMA(1 1 3)(1 0 0)	-888,18	-868,481	0,024542
SARIMA(1 1 3)(1 0 1)	-886,373	-863,391	0,02453
SARIMA(1 1 3)(1 0 2)	-884,381	-858,115	0,02453
SARIMA(1 1 3)(1 0 3)	-882,18	-852,631	0,024542
SARIMA(1 1 3)(2 0 0)	-892,919	-869,936	0,024091
SARIMA(1 1 3)(2 0 1)	-890,979	-864,713	0,024087
SARIMA(1 1 3)(2 0 2)	-902,367	-872,819	0,023101
SARIMA(1 1 3)(2 0 3)	-882,205	-849,373	0,024412
SARIMA(1 1 3)(3 0 0)	-896,551	-870,285	0,023653
SARIMA(1 1 3)(3 0 1)	-894,685	-865,137	0,023642
SARIMA(1 1 3)(3 0 2)	-882,219	-849,387	0,024412
SARIMA(1 1 3)(3 0 3)	-880,234	-844,119	0,024411
SARIMA(2 1 0)(0 0 0)	-891,607	-881,757	0,024706
SARIMA(2 1 0)(0 0 1)	-889,779	-876,646	0,024695
SARIMA(2 1 0)(0 0 2)	-892,26	-875,844	0,024408
SARIMA(2 1 0)(0 0 3)	-888,377	-868,678	0,02453
SARIMA(2 1 0)(1 0 0)	-889,831	-876,699	0,024691
SARIMA(2 1 0)(1 0 1)	-890,603	-874,187	0,024515
SARIMA(2 1 0)(1 0 2)	-894,5	-874,801	0,02412
SARIMA(2 1 0)(1 0 3)	-892,919	-869,936	0,024091
SARIMA(2 1 0)(2 0 0)	-887,794	-871,378	0,024694
SARIMA(2 1 0)(2 0 1)	-885,832	-866,132	0,024691
SARIMA(2 1 0)(2 0 2)	-891,471	-868,488	0,024187
SARIMA(2 1 0)(2 0 3)	-890,5	-864,235	0,02412
SARIMA(2 1 0)(3 0 0)	-889,819	-870,12	0,024438
SARIMA(2 1 0)(3 0 1)	-888,469	-865,487	0,024396
SARIMA(2 1 0)(3 0 2)	-900,931	-874,665	0,02316

SARIMA(2 1 0)(3 0 3)	-900,004	-870,455	0,023104
SARIMA(2 1 1)(0 0 0)	-889,779	-876,646	0,024695
SARIMA(2 1 1)(0 0 1)	-887,848	-871,432	0,02469
SARIMA(2 1 1)(0 0 2)	-893,574	-873,875	0,024158
SARIMA(2 1 1)(0 0 3)	-886,382	-863,4	0,02453
SARIMA(2 1 1)(1 0 0)	-890,603	-874,187	0,024515
SARIMA(2 1 1)(1 0 1)	-890,142	-870,443	0,024417
SARIMA(2 1 1)(1 0 2)	-888,13	-865,147	0,024417
SARIMA(2 1 1)(1 0 3)	-890,979	-864,713	0,024087
SARIMA(2 1 1)(2 0 0)	-885,832	-866,132	0,024691
SARIMA(2 1 1)(2 0 1)	-886,631	-863,648	0,024513
SARIMA(2 1 1)(2 0 2)	-890,5	-864,235	0,02412
SARIMA(2 1 1)(2 0 3)	-888,968	-859,419	0,024088
SARIMA(2 1 1)(3 0 0)	-888,469	-865,487	0,024396
SARIMA(2 1 1)(3 0 1)	-885,811	-859,546	0,024438
SARIMA(2 1 1)(3 0 2)	-900,004	-870,455	0,023107
SARIMA(2 1 1)(3 0 3)	-898,46	-865,628	0,023082
SARIMA(2 1 2)(0 0 0)	-892,26	-875,844	0,024408
SARIMA(2 1 2)(0 0 1)	-893,574	-873,875	0,024158
SARIMA(2 1 2)(0 0 2)	-886,221	-863,239	0,024539
SARIMA(2 1 2)(0 0 3)	-884,506	-858,24	0,024522
SARIMA(2 1 2)(1 0 0)	-894,5	-874,801	0,02412
SARIMA(2 1 2)(1 0 1)	-888,13	-865,147	0,024417
SARIMA(2 1 2)(1 0 2)	-886,121	-859,855	0,024418
SARIMA(2 1 2)(1 0 3)	-899,863	-870,314	0,023339
SARIMA(2 1 2)(2 0 0)	-891,471	-868,488	0,024187
SARIMA(2 1 2)(2 0 1)	-890,5	-864,235	0,02412
SARIMA(2 1 2)(2 0 2)	-884,044	-854,495	0,024423
SARIMA(2 1 2)(2 0 3)	-896,349	-863,517	0,023484
SARIMA(2 1 2)(3 0 0)	-900,931	-874,665	0,02316
SARIMA(2 1 2)(3 0 1)	-900,003	-870,454	0,023104
SARIMA(2 1 2)(3 0 2)	-896,156	-863,324	0,023506
SARIMA(2 1 2)(3 0 3)	-895,007	-858,892	0,023147
SARIMA(2 1 3)(0 0 0)	-888,377	-868,678	0,02453
SARIMA(2 1 3)(0 0 1)	-886,382	-863,4	0,02453
SARIMA(2 1 3)(0 0 2)	-884,506	-858,24	0,024522
SARIMA(2 1 3)(0 0 3)	-882,634	-853,085	0,024514
SARIMA(2 1 3)(1 0 0)	-892,919	-869,936	0,024091
SARIMA(2 1 3)(1 0 1)	-890,979	-864,713	0,024087
SARIMA(2 1 3)(1 0 2)	-902,367	-872,819	0,023101
SARIMA(2 1 3)(1 0 3)	-882,205	-849,373	0,024412
SARIMA(2 1 3)(2 0 0)	-890,5	-864,235	0,02412
SARIMA(2 1 3)(2 0 1)	-888,968	-859,419	0,024088
SARIMA(2 1 3)(2 0 2)	-896,349	-863,517	0,023484
SARIMA(2 1 3)(2 0 3)	-880,397	-844,282	0,024399
SARIMA(2 1 3)(3 0 0)	-900,004	-870,455	0,023104

SARIMA(2 1 3)(3 0 1)	-898,46	-865,628	0,023082
SARIMA(2 1 3)(3 0 2)	-895,006	-858,89	0,023146
SARIMA(2 1 3)(3 0 3)	-892,166	-852,767	0,023505
SARIMA(3 1 0)(0 0 0)	-890,318	-877,185	0,024661
SARIMA(3 1 0)(0 0 1)	-891,291	-874,875	0,024471
SARIMA(3 1 0)(0 0 2)	-900,507	-880,808	0,023658
SARIMA(3 1 0)(0 0 3)	-898,499	-875,517	0,023662
SARIMA(3 1 0)(1 0 0)	-891,749	-875,333	0,024442
SARIMA(3 1 0)(1 0 1)	-890,253	-870,553	0,02441
SARIMA(3 1 0)(1 0 2)	-898,507	-875,524	0,023658
SARIMA(3 1 0)(1 0 3)	-896,544	-870,279	0,023655
SARIMA(3 1 0)(2 0 0)	-889,819	-870,12	0,024438
SARIMA(3 1 0)(2 0 1)	-888,469	-865,487	0,024396
SARIMA(3 1 0)(2 0 2)	-900,931	-874,665	0,023159
SARIMA(3 1 0)(2 0 3)	-900,004	-870,455	0,023104
SARIMA(3 1 0)(3 0 0)	-885,404	-862,421	0,024591
SARIMA(3 1 0)(3 0 1)	-884,045	-857,779	0,02455
SARIMA(3 1 0)(3 0 2)	-885,091	-855,542	0,024341
SARIMA(3 1 0)(3 0 3)	-886,799	-853,967	0,024096
SARIMA(3 1 1)(0 0 0)	-891,291	-874,875	0,024471
SARIMA(3 1 1)(0 0 1)	-890,142	-870,443	0,024416
SARIMA(3 1 1)(0 0 2)	-888,136	-865,154	0,024417
SARIMA(3 1 1)(0 0 3)	-886,218	-859,953	0,024412
SARIMA(3 1 1)(1 0 0)	-890,253	-870,553	0,02441
SARIMA(3 1 1)(1 0 1)	-888,143	-865,16	0,024416
SARIMA(3 1 1)(1 0 2)	-896,528	-870,262	0,023656
SARIMA(3 1 1)(1 0 3)	-894,686	-865,137	0,023643
SARIMA(3 1 1)(2 0 0)	-888,469	-865,487	0,024396
SARIMA(3 1 1)(2 0 1)	-885,811	-859,546	0,024438
SARIMA(3 1 1)(2 0 2)	-900,004	-870,455	0,023104
SARIMA(3 1 1)(2 0 3)	-898,46	-865,628	0,023082
SARIMA(3 1 1)(3 0 0)	-884,045	-857,779	0,02455
SARIMA(3 1 1)(3 0 1)	-883,884	-854,335	0,024433
SARIMA(3 1 1)(3 0 2)	-895,371	-862,539	0,023556
SARIMA(3 1 1)(3 0 3)	-885,697	-849,581	0,024036
SARIMA(3 1 2)(0 0 0)	-900,507	-880,808	0,023658
SARIMA(3 1 2)(0 0 1)	-888,136	-865,154	0,024417
SARIMA(3 1 2)(0 0 2)	-886,142	-859,876	0,024417

SARIMA(3 1 2)(0 0 3)	-884,213	-854,664	0,024412
SARIMA(3 1 2)(1 0 0)	-898,507	-875,524	0,023658
SARIMA(3 1 2)(1 0 1)	-896,509	-870,244	0,023659
SARIMA(3 1 2)(1 0 2)	-894,521	-864,972	0,023745
SARIMA(3 1 2)(1 0 3)	-882,219	-849,387	0,024412
SARIMA(3 1 2)(2 0 0)	-900,931	-874,665	0,02316
SARIMA(3 1 2)(2 0 1)	-900,004	-870,455	0,023104
SARIMA(3 1 2)(2 0 2)	-896,156	-863,324	0,023506
SARIMA(3 1 2)(2 0 3)	-899,78	-863,665	0,022766
SARIMA(3 1 2)(3 0 0)	-885,091	-855,542	0,024341
SARIMA(3 1 2)(3 0 1)	-895,371	-862,539	0,023556
SARIMA(3 1 2)(3 0 2)	-888,92	-852,805	0,023827
SARIMA(3 1 2)(3 0 3)	-898,957	-859,558	0,023062
SARIMA(3 1 3)(0 0 0)	-898,499	-875,517	0,023662
SARIMA(3 1 3)(0 0 1)	-886,218	-859,953	0,024412
SARIMA(3 1 3)(0 0 2)	-884,213	-854,664	0,024412
SARIMA(3 1 3)(0 0 3)	-882,192	-849,36	0,024413
SARIMA(3 1 3)(1 0 0)	-896,523	-870,257	0,023654
SARIMA(3 1 3)(1 0 1)	-894,685	-865,136	0,023644
SARIMA(3 1 3)(1 0 2)	-882,219	-849,387	0,024412
SARIMA(3 1 3)(1 0 3)	-880,234	-844,119	0,024411
SARIMA(3 1 3)(2 0 0)	-900,004	-870,455	0,023104
SARIMA(3 1 3)(2 0 1)	-898,46	-865,628	0,023082
SARIMA(3 1 3)(2 0 2)	-895,001	-858,886	0,023147
SARIMA(3 1 3)(2 0 3)	-892,166	-852,767	0,023505
SARIMA(3 1 3)(3 0 0)	-886,799	-853,967	0,024096
SARIMA(3 1 3)(3 0 1)	-885,696	-849,581	0,024037
SARIMA(3 1 3)(3 0 2)	-898,957	-859,558	0,023062
SARIMA(3 1 3)(3 0 3)	-895,595	-852,914	0,023155